

SAY-6 파이널 프로젝트 결과보고서

[6 팀] 파이널 프로젝트 결과보고서

EMON Med®

Emergency Multi-modal Orchestrated Network

AI 기반 응급실 멀티모달 능동형 의사결정 지원 시스템

AWS 바이오헬스케어 부트캠프 · 성균관대학교

항목	내용
프로젝트명	AI 기반 응급실 멀티모달 능동형 의사결정 지원 시스템 (SAY-2-6 팀)
소속	AWS SAY 2 기 [6 팀]
수행 기간	2026.04.17 ~ 2026.05.28 (Final Project)
보고서 작성일	2026.05.24
배포 환경	AWS ap-northeast-2 (서울 리전) · CloudFront · ECS Fargate
코드/데이터 저장소	GitHub: [URL] / S3: say2-6team-bucket / Aurora central_db
팀 구성	원정아, 이정인, 양정인, 홍경태

목 차

장	제목
0	초록 (Abstract)
1	프로젝트 개요
2	문제 정의
3	프로젝트 관리
4	데이터
5	시스템 아키텍처
6	모델 개발
7	백엔드 · 인프라
8	프론트엔드 · UX
9	성능 평가 및 검증
10	사업적 의의 · 기술적 의의 · 확장성
11	검증 로드맵 및 인허가
12	결론
13	한계 및 향후 과제
부록	코드 구조 · API · 스키마 · 시연 · 참고문헌 · 용어집

0. 초록 (Abstract)

본 프로젝트는 2024 년 의료대란 이후 한국 응급의료 전달체계가 직면한 구조적 위기 — 지역 응급의료기관 응급의학 전문의 1.9 명/소라는 야간주말 의사결정 공백, 전원 사유 26.6%를 차지하는 「전문응급의료 요함」, KTAS 3 환자 비중 52.9%로의 2 년 연속 상승 — 를 정량 근거로 「응급실 야간 당직 의사결정 지원」을 단일 사용 시나리오로 정의하고, ECGCXR·Lab·Note RAG 4 개 모달을 능동형으로 조합한 멀티모달 AI 시스템(SAY-6)을 설계·구현·검증했다.

핵심 기술 기여는 다음 다섯 가지다. (1) S6(Mamba) State Space Model 기반 12-lead ECG 24-disease multi-label 분류기로 ECG-MIMIC 논문 대비 4 가지(ED 첫 ECG 데이터 / 24 라벨 임상 기반 수동 선정 / 인구통계 결합 / 30 일 사망률 가중 BCE Loss)를 차별화하여 **Macro AUROC 0.814** 를 달성. (2) UNet 페 세그멘테이션과 DenseNet-121 분류를 교차검증하는 CXR 모달로 6-disease 를 150~300ms 에 판독. (3) <10ms 결정론적 Rule Engine + 7 Chief Complaint Profile + XGBoost 6 시간 예후의 3-Stage Lab 모달로 SaMD Class I~II 규제 적합성과 「놓침방지」를 동시 확보. (4) Bedrock Claude Haiku/Sonnet 동적 라우팅 기반 9 섹션 한국어 임상 소견서 자동 생성 (RAG 근거 인용 + SYSTEM PROMPT 9 원칙). (5) Chief Complaint — 첫 모달 → 결과 → 다음 모달 결정의 Active Cross-Modal Routing (최대 3 loop)으로 비용·시간 최적화.

AWS ap-northeast-2(서울) 리전에 ECS Fargate(GPU-free) + Aurora Serverless v2 + Bedrock + CloudFront(217 PoP) 구조로 Multi-AZ 배포. Web 모니터링 스테이션(React 18) + Mobile 의사용 앱(Flutter + FCM Critical Push)을 통해 의사가 응급실 PC 를 떠나 있어도 골든타임을 확보할 수 있게 한다.

정량적 시장 가치는 연 7.2 만건의 AI 개입 가능 전원(전체 13.3 만건 × 54.4%)으로 환산되며, 3 년 ARR SOM 은 45~60 억으로 추정된다. Phase 1 Silent — Shadow — Prospective 3 단계 검증 로드맵과 식약처 SaMD Class II 인허가 트랙을 병행하여 5 년 내 전국 528 개 응급의료기관 50% 이상 도입을 목표한다.

주요 키워드

응급실, KTAS, NEDIS, 멀티모달 AI, S6 Mamba, UNet, DenseNet, RAG, Bedrock Claude, FHIR R4, SaMD, ECS Fargate, Aurora Serverless v2, Active Routing

1. 프로젝트 개요

1.1 프로젝트 정보

항목	내용
프로젝트명	SAY-6 — 응급실 멀티모달 능동형 AI 의사결정 지원 시스템
수행 기간	2026.04.17 ~ 2026.05.28 (6 주, Final Project)
주관	AWS 바이오헬스케어 부트캠프 · 성균관대학교 SAY 2 기
팀명·구성	6 팀 / 5 명 (Backend / ML / Frontend / Mobile / Clinical)
대상 도메인	응급의료 (KTAS 2~3, 야간주말 당직 시간대)
주 사용자	지역응급의료센터·기관의 야간 당직 의사 + 모니터링 간호사

1.2 한 줄 정의

주호소만 입력하면 AI 가 ECGCXRLab 을 능동 호출하고 9 섹션 한국어 임상 소견서를 자동 생성한다.

1.3 3대 핵심 가치 (Value Proposition)

가치	정의	정량 목표	통계연보 근거
시간단축	Door-to-Decision 시간 단축	50-15 분 / D2B 90-60 분	재실 2h 미만 48.8%
놓침방지	필수 검사중증도 누락 방지	panel 누락 15~20%-5%	전원 26.6% 「전문응급요함」
법적방어	Audit log + 가이드라인 인용	모든 판단 timestamp + 근거 저장	소송의 주된 쟁점

1.4 배포 환경 및 산출물

구분	URL · 위치
배포 리전	AWS ap-northeast-2 (서울)
CDN	CloudFront 217 PoP
데모 사이트	https://[도메인].cloudfront.net
코드 저장소	GitHub: github.com/[org]/say-6-project

구분	URL·위치
S3 버킷	say2-6team-bucket (ECG WFDB / CXR PNG / 모델 ONNX)
DB	Aurora Serverless v2 — central_db + hapi (HAPI FHIR)
시연 영상	[URL] (Case 1~5, 5~7 분)
API 명세	/docs (각 svc OpenAPI Swagger)

2. 문제 정의

2.1 의료대란 이후 응급실 이용 18.6% 급감 — 도달 실패의 정량 신호

2024년 2월 전공의 집단 사직 이후 한국 응급의료 전달체계는 구조적 재편을 겪었다. 2024 응급의료 통계연보(제 23 호, 중앙응급의료센터 2025.10 발간)에 따르면 전국 응급실 이용 건수는 7,844,739 건으로 전년(9,642,461 건) 대비 1,797,722 건(△18.6%) 급감했으며, 인구 천명당 이용률은 187.9 건에서 153.2 건으로 5년 내 최저치를 기록했다. 응급 의료 수요 자체가 감소한 것이 아니라, 환자가 적시에 응급실에 도달하지 못한 결과로 해석된다.

지표	2022	2023	2024	변동	해석
응급실 이용	8,155,437	9,642,461	7,844,739	△18.6%	5년 내 최저
천명당 이용률	157.9	187.9	153.2	△34.7	도달 실패
귀가 비율	74.5%	75.0%	71.4%	△3.6	귀가↓ = 입원↑
입원 비율	22.8%	22.8%	26.0%	+3.2	2차 부담↑
전원 비율	1.7%	1.5%	1.7%	+0.2	전원 수요 유지
외부 전원 유입률	9.6%	9.9%	11.1%	+1.2	2차 유입 부담

2.2 응급실 야간 당직 의사결정 공백 — 전문의 1.9 명/소

통계연보 p.40에 따르면 24시간 전담의사 근무 충족율은 권역 100%, 지역응급의료센터 98.5%, 지역응급의료기관 90.4%로 「전담의사 배치」 자체는 대부분 충족된다. 그러나 p.46의 응급실 전담 의료진 현황을 보면 1개소당 응급의학 전문의 수는 권역 10.1명, 지역응급의료센터 7.0명인 반면 지역응급의료기관은 1.9명에 불과하다. 전문의 1.9명으로는 24시간 교대근무가 구조적으로 불가능하며, 야간주말에는 응급의학 비전문 당직(타과 전문의·일반의·당직)이 주요 결정을 수행하게 된다.

기관 유형	기관 수	1개소당 전문의	24h 교대 가능성	본 시스템 가치
권역응급의료센터	44	10.1명	충족	낮음
지역응급의료센터	137	7.0명	편차 존재	높음 (Phase 1 타킷)
지역응급의료기관	233	1.9명	구조적 불가	최대 (Phase 3)

기관 유형	기관 수	1개소당 전문의	24h 교대 가능성	본 시스템 가치
응급의료시설	114	—	—	—
계 / 평균	528	4.4 명	94.1%	—

2.3 환자 전원 「뽕뽕이」 — 전원 사유 26.6%가 「전문응급의료 요함」

통계연보 p.22 그림 29의 전원 사유 분포를 보면, 본 시스템의 AI 개입 가능 영역(전문응급의료 요함 + 응급수술 처치불가 + 회송 + 경증 전원)이 54.4%에 달한다. 2024년 전원 건수 약 133,000건 중 약 72,000건/년이 정량 시장이다.

전원 사유	비중	AI 개입	해당 모달	본 시스템 기여
전문응급의료 요함	26.6%	◎ 매우 높음	Note RAG	2차 판단 한계 보완
환자보호자 사정	22.8%	△ 낮음	해당없음	—
응급수술 처치불가	15.4%	○ 중간	CXR+ECG+Lab	장비·인력 한계 사전 인식
병실 부족	12.1%	△	—	—
회송	6.7%	○	Note RAG	회송 근거 문서화
경증으로 전원	5.7%	○	Note RAG	중증도 오분류 감지
기타/요양/중환자실 부족	10.7%	△	—	—
AI 개입 가능 합계	54.4%	—	—	약 72,000 건/년 정량 시장

2.4 골든타임 손실 — 5대 중증질환 감소의 의미

주요 중증응급질환 5종 모두 2024년에 전년 대비 감소했다. 허혈성 뇌졸중 △11.2%, 중증외상 △14.4%는 단순한 수요 감소가 아니라 골든타임 내 치료 기회 상실을 시사한다. 특히 출혈성 뇌졸중 전원을 36.1%는 5대 질환 중 최고로, 2차→3차 전원이 구조적으로 필요한 본 프로젝트의 Transfer Decision Support 핵심 타깃이다.

질환	2022	2023	2024	퇴원율	전원율	사망률
심근경색 (I21)	36,935	38,662	35,142	81.1%	9.5%	9.0%

질환	2022	2023	2024	퇴원율	전원율	사망률
출혈성 뇌졸중 (I60-62)	30,975	32,514	30,090	46.8%	36.1%	15.8%
허혈성 뇌졸중 (I63-64)	94,916	100,088	88,914	71.7%	22.4%	5.3%
중증외상 (ICISS<0.9)	86,159	93,541	80,072	67.2%	25.1%	6.9%
심장정지 (I46)	35,637	26,986	25,839	9.9%	8.5%	81.0%

2.5 기존 단일 모달 AI의 한계 — 통합 의사결정 부재

국내·외 의료 AI 시장은 단일 모달 위주로 형성되어 있다. 뷰노 Med-ECGDeepCARS는 ECG 단독, 루닛 INSIGHT CXR는 흉부 영상 단독, Aidoc은 CT/CXR 중심으로 응급실의 다모달 통합 의사결정 흐름은 부재하다. 또한 어느 시스템도 ① 한국형 KTAS 168 증례, ② 능동형 모달 라우팅, ③ 한국어 9섹션 임상 소견서 자동 생성, ④ FHIR R4 표준의 4가지를 동시에 만족하지 못한다.

2.6 해결 가설 — Chief Complaint 기반 능동형 멀티모달 라우팅

「주호소(Chief Complaint)를 입력하면, AI가 첫 모달을 선택 → 결과를 보고 → 다음 모달을 능동 호출 → 최종 통합 소견서를 생성한다」 — 모든 모달을 동시에 돌리지 않고 필요한 것만 능동 호출하여, 응급실 자원/시간/비용을 동시에 최적화한다.

본 가설은 ① 결정론적 Rule(Lab) + ② ML(ECG/CXR) + ③ LLM(Note RAG)의 3-tier 하이브리드, ④ Active Cross-Modal Routing의 4축으로 구체화되며, 본 보고서 제 5장 시스템 아키텍처와 제 6장 모델 개발에서 상세 설계된다.

3. 프로젝트 관리

3.1 팀 구성 및 업무 분담

역할	팀원	주요 담당	관련 모듈
Project Lead	원정아	전체 일정·산출물 관리·발표	프로젝트 전반
ML Lead (ECG)	양정인	S6 Mamba 학습·ONNX 변환·thresholds 튜닝	ecg-svc
ML Lead (CXR)	이정인	UNet+DenseNet 학습·교차검증·heatmap	chest-svc
Backend Lead	홍경태	Central Orchestrator·FHIR·Lab·Ruler·router	central, Lab-svc, rag-svc, router-svc
Frontend & UX	원정아	Web(React)·Mobile(Flutter)·디자인 시스템	frontend, mobile, design-system
AWS Infra (분담)	전 팀원 공동	네트워크·컴퓨팅·보안·DB·모니터링 5 영역 분담	AWS/

3.2 WBS 및 일정 — 6 주 스케줄

주차	기간	마일스톤	주요 산출물
W1	04.17 ~ 04.23	사전 분석·요구사항 정의	문제 정의서·페르소나·KTAS 매핑
W2	04.24 ~ 04.30	데이터 준비·EDA	MIMIC-IV·CXR·NOTE 로딩·전처리
W3	05.01 ~ 05.07	모델 학습 (ECG/CXR/Lab)	S6 Mamba weights, DenseNet ONNX, Rule Engine
W4	05.08 ~ 05.14	통합 (Central + RAG + FHIR)	Hybrid Decision Engine, Bedrock Claude 연동
W5	05.15 ~ 05.21	AWS 인프라·UI/UX 구축	ECS Fargate·Aurora·Web/Mobile dist
W6	05.22 ~ 05.28	검증·시연·보고서	5 Case 시연·골든셋 평가결과보고서

3.3 개발 환경 및 협업 도구

영역	도구	용도
코드 저장소	GitHub (Private)	버전 관리·PR 리뷰·Release

영역	도구	용도
프로젝트 관리	Notion	WBS회의록기술 메모
커뮤니케이션	Slack + Google Meet	일일 standup이슈 트래킹
디자인	Figma + 자체 design-system HTML	UI 시안핸드오프
로컬 개발	Docker Compose (final/central/infra)	통합 로컬 테스트
IaC	AWS CloudFormation	5 스택 (network/security/compute/d ata/monitoring)
ML 학습 환경	PyTorch + ONNX + AWS SageMaker (option)	S6 Mamba / UNet+DenseNet
CI/CD	GitHub Actions + ECR + ECS deploy	빌드-테스트배포 자동화

3.4 마일스톤 요약

일자	달성 항목
2026.04.17	킵오프 — 프로젝트 범위·역할 분담
2026.04.30	EDA 완료 — MIMIC-IV ECG 158K + CXR 골든셋
2026.05.07	ECG S6 Macro AUROC 0.814 달성
2026.05.14	Central + Note RAG 통합 (Bedrock Claude 연동)
2026.05.21	AWS 인프라 5 스택 배포 + Web/Mobile 첫 빌드
2026.05.24	5 Case 시연 검증 + 본 보고서 작성
2026.05.28	최종 발표

4. 데이터

4.1 학습 데이터셋 개요

데이터셋	용도	규모	출처	라이선스
MIMIC-IV ECG	ECG S6 학습	800,035 건 (ED 첫 ECG 158,440 건 추출)	PhysioNet (BIDMC)	PhysioNet Credentialed
MIMIC-CXR	CXR DenseNet pre-train	CheXpert 14-label	PhysioNet	PhysioNet Credentialed
MIMIC-NOTE	RAG corpus	퇴원요약 5 만+	PhysioNet	PhysioNet Credentialed
PTB-XL ECG	Cross-dataset 정규화 통계	21,799 명 (베를린)	PhysioNet	Open
NEDIS 통계연보	한국 응급의료 현황	권역·지역센터 181 개소, 99.8% 전송	중앙응급의료센터	공개
e-MEDIS / HIRA	주호소·검사 패턴 보완	—	복지부·건보심사평가원	신청 후 사용

4.2 NEDIS 한국 응급의료 자원 현황 (2024)

기관 유형	기관 수	총 병상	평균 병상	주요 기능
권역응급의료센터	44	1,468	33.4	3 차 — 최종치료·전원 수용
지역응급의료센터	137	3,259	24.0	2 차 — 본 프로젝트 타깃
지역응급의료기관	233	2,467	10.6	경증1차 선별
응급의료시설	114	—	—	분만·소아 등 전문
계	528	7,194	—	—

4.3 KTAS 중증도 분포 (2022~2024)

KTAS Level	임상 의미	2022	2023	2024	본 시스템 합의
Level 1	소생 (즉시 위험)	1.3%	1.3%	1.8%	RAG Critical - 최우선
Level 2	긴급 (생명 위험)	5.8%	6.1%	8.0%	3 모달 우선 가동
Level 3	응급	43.4%	45.7%	52.9%	주력 타겟 (+7.2%p)
Level 4	준응급	39.4%	38.6%	31.5%	경증 선별
Level 5	비응급	10.0%	8.3%	5.7%	회송 대상

4.4 24 개 ECG 타겟 라벨 — 임상 기반 수동 선정

ECG-MIMIC 논문은 빈도 기반 자동 라벨링을 사용하지만, 본 시스템은 응급실 임상 의사결정에 직결되는 14 개 심혈관 + 10 개 비심혈관 = 24 개 라벨을 수동 선정했다.

4.4.1 1 차 타겟 — 심혈관 14 종

질환	ICD-10	건수	비율	Tier (사망률)
고혈압	I10	55,498	35.0%	Tier 3
만성 허혈성 심 질환	I25	28,709	18.1%	Tier 2
심부전	I50	23,344	14.7%	Tier 2
심방세동/조동	I48	22,826	14.4%	Tier 2
급성 심근경색	I21	5,239	3.3%	Tier 1 (12.7%)
발작성 빈맥	I47	3,054	1.9%	Tier 1 (11.6%)
방실차단/좌각 차단	I44	2,690	1.7%	Tier 2
폐색전증	I26	2,011	1.3%	Tier 1 (11.7%)
기타 전도장애	I45	1,854	1.2%	Tier 2
협심증	I20	1,474	0.9%	Tier 3
심낭질환	I31	1,224	0.8%	Tier 1 (10.6%)

질환	ICD-10	건수	비율	Tier (사망률)
심정지	I46	813	0.5%	Tier 1 (60.1%)

4.4.2 2 차 타겟 — 비심혈관 10 종 (ECG 간접 단서)

질환	ICD-10	건수	비율	Tier
급성 신부전	N17	19,376	12.2%	Tier 1 (12.6%)
고칼륨혈증	E875	5,902	3.7%	Tier 1 (12.6%)
패혈증	R65	4,167	2.6%	Tier 1 (28.1%)
호흡부전	J96	7,408	4.7%	Tier 1 (27.5%)
만성 신장질환	N18	22,122	14.0%	Tier 2
제 2 형 당뇨병	E119	21,581	13.6%	Tier 3
갑상선기능저하 증	E039	13,567	8.6%	Tier 2
COPD	J44	12,503	7.9%	Tier 2
저칼륨혈증	E876	4,335	2.7%	Tier 2
칼슘 대사 이상	E835	1,741	1.1%	Tier 1 (12.1%)

4.5 데이터 분할 — 20-fold Stratified Cross Validation

구분	Fold	건수
Train	0~15	125,841 건
Validation	16~17	16,103 건
Test	18~19	15,514 건
합계	—	158,440 건 (ED 첫 ECG)

4.6 MIMIC-IV vs NEDIS — Domain Adaptation 격차

항목	MIMIC-IV (학습)	NEDIS (한국 현장)	해결 방향
중증도 체계	ESI Level 1-5	KTAS Level 1-5	ESI→KTAS 매핑 레이어
인구 구성	미국 다인종, BIDMC	80+ 12.8% 고령 비중	연령 가중 재학습

항목	MIMIC-IV (학습)	NEDIS (한국 현장)	해결 방향
	단일	높음	
평균 재실시간	4~6 시간	48.8%가 2 시간 이내	Decision speed 최적화
전원 개념	제한적 (in-hospital)	11.1% 유입, 9 분류	한국 특화 Transfer Decision 모듈
내원수단	EMS자가이송 혼재	자가 71.6%, 119 23.9%	주호소 분류 정교화
EMR 표준	OMOP CDM	FHIR R4 (식약처 권장)	FHIR adapter
언어	영어 임상기록	한국어 임상기록	한국어 Note RAG
Lab 분포	ICU 집중, 극단값	응급·외래 혼합	정규화 재보정

5. 시스템 아키텍처

5.1 전체 아키텍처 한눈에

본 시스템은 3개 AI 모달 + 1개 Note RAG 오케스트레이터 + 1개 Central 능동형 결정 엔진 + 1개 풀백 라우터 + Web/Mobile 클라이언트 + AWS 인프라의 8-Layer 구조로 설계된다. 아래 다이어그램은 AWS ap-northeast-2(서울) 리전 기준의 전체 시스템 토폴로지, 사용자 트래픽(파란색), AI 추론 흐름(빨간색), 데이터 저장조회(초록색), 보안인증(보라색), 모니터링·알림(주황색), RAG임베딩 흐름(갈색)의 6개 색상 범례로 트래픽 경로가 구분된다.

시스템 아키텍처 | EMON — 응급실 AI 진단보조 시스템

AWS ap-northeast-2 (서울) · ECS Fargate · Aurora Serverless v2 · Amazon Bedrock Claude · FHIR R4




그림 5-1. EMON Med® 전체 시스템 아키텍처 (AWS ap-northeast-2 · ECS Fargate · Aurora Serverless v2 · Bedrock Claude · FHIR R4)

Layer	구성 요소	기술	역할
Client	Web Frontend / Mobile App	React 18 + Vite + Tailwind / Flutter + Riverpod + FCM	의사 PC + 폰 인터페이스
Gateway	ALB + CloudFront + WAF	AWS Edge	TLS1.3 + Rate-limit + Geo-blocking
Orchestration	Central Orchestrator (final/central)	FastAPI + Hybrid Decision Engine + HAPI FHIR	능동형 결정 + 9 섹션 소견서
AI Modal	ECG / CXR / Lab svc	S6 Mamba ONNX / UNet+DenseNet / Rule+XGBoost	병렬 추론 (<1s / <1.5s / <50ms)
LLM RAG	Note RAG (rag-svc) + Data-RAG	Bedrock Claude Haiku/Sonnet + FAISS	9 섹션 소견서 + RAG 근거
Fallback	Router-svc	FastAPI Stateless 프록시	Central 장애 시 BCP/DR
Data	Aurora Serverless v2 + S3 + HAPI FHIR	PostgreSQL + WFDB/PNG/ONNX	central_db + ops_modal_results + 원본
Infra	ECS Fargate + Cloud Map + VPC	Multi-AZ, GPU-free	ap-northeast-2 서울 리전

5.2 데이터 흐름 (Encounter Lifecycle)

단계	주체	행위	주요 자원
①	분류 간호사	트리아지 입력 (주호소, KTAS, V/S)	FHIR Patient + Encounter + Observation
②	Central	Chief Complaint → 첫 모달 결정 (Hybrid ML + CC Map)	FHIR ServiceRequest (draft)
③	의사	Web/Mobile 에서 AI 권고 검토·승인	ServiceRequest (active)
④	ECG/CXR/Lab	병렬 분석 (1s / 1.5s / 50ms)	Modal Result + Aurora 저장
⑤	Central	결과 보고 → 다음 모달 결정 (최대 3 loop)	ServiceRequest (반복)
⑥	Note RAG	9 섹션 한국어 소견서 생성	Bedrock Claude + RAG
⑦	의사	Face ID 서명 → 완료	DocumentReference + audit log

5.3 능동형 라우팅 (Active Cross-Modal Routing)

Chief Complaint 입력부터 최종 소견서까지의 결정 흐름은 다음과 같다. 모든 결정은 MIMIC 데이터에서 학습된 ML 로 이루어지며, 하드코딩된 임상 룰은 없다.

Confidence	임계값	Decision Engine Action
VERY_HIGH	≥ 0.95	즉시 다음 단계 진행
HIGH	≥ 0.90	CALL_NEXT_MODALITY (능동 호출)
MEDIUM	≥ 0.70	NEED_REASONING (Bedrock 종합 추론)
LOW	≥ 0.50	추가 정보 요청 (의사 입력 보조)
VERY_LOW	< 0.50	GENERATE_REPORT (현재까지 정보로 종결)

5.4 핵심 설계 원칙 — 3 Principles

원칙	내용	구현 위치
Rule-First	결정론적 Rule 이 1 차 — ML/LLM 은 보강. <10ms100% 재현성SaMD Class I 적합	Lab-svc Stage A 11 Critical Flag
Audit-Log-by-Design	모든 판단근거timestamp 자동 기록. 법적 분쟁 방어 + SaMD 추적성	Central + Aurora ops_ * 테이블 + CloudWatch
Fail-Safe Fallback	Central 장애 시 router-svc Stateless 폴백. RAG 장애 시 Bedrock direct 호출	router-svc + rag-svc fallback prompt

6. 모델 개발

6.1 ECG 모달 — S6 (Mamba) State Space Model

6.1.1 모델 아키텍처

구성	값	비고
CNN stem	Conv1d(12→128, k=7) → 128→256(k=5) → 256→512(k=3), stride=2	시퀀스 1000→500→250→125
MambaBlock	6 개 (MambaLayer + FFN)	Selective Scan (S4 대비 동적 파라미터)
d_model	512	—
d_state	64	—
인구통계 결합	FC(2→32) GELU → concat (32-dim 임베딩)	나이/성별
출력 head	LayerNorm → FC(544→128) GELU → FC(128→24)	24 개 질환 logit
총 파라미터	약 9M	ONNX 경량 추론 가능

6.1.2 신호 전처리 파이프라인

단계	처리	근거
1	wfdb 로딩 → (5000, 12) float32	MIMIC 표준 포맷
2	NaN 선형 보간 + ±3mV 클리핑	노이즈 제거
3	resampy 리샘플링 500Hz → 100Hz → (1000, 12)	모델 입력 크기 표준화
4	12 채널 고정 순서 정렬 (I, II, V1~V6, III, aVR, aVL, aVF)	리드 순서 일관성
5	PTB-XL 채널별 Z-score 정규화 + ±5σ 클리핑	Cross-dataset 일반화
6	모델 입력 (batch, 12, 1000)	—

6.1.3 차별화 ① — 인구통계 결합

ECG-MIMIC 논문은 ECG 신호만 입력하지만, 본 모델은 나이(0~1 normalized)와 성별(M=1.0, F=0.0, 미상=0.5)을 추가 입력으로 결합한다. 같은 ECG 파형도 환자에 따라 임상적 의미가 다르기 때문이다 — Afib 유병률은 50대 2% → 80대 15%로 7배 차이가 난다.

6.1.4 차별화 ② — 30 일 사망률 가중 BCE Loss

ECG-MIMIC 논문은 모든 질환에 동등 가중 BCE 를 사용하지만, 본 모델은 MIMIC-IV 실제 30 일 사망률 데이터를 기반으로 Tier 별 가중치를 부여한다.

Tier	기준	가중치	질환 예시
Tier 1	사망률 $\geq 10\%$	3.0	심정지(60.1%), 패혈증(28.1%), 호흡부전(27.5%), 급성 MI(12.7%)
Tier 2	사망률 5~10%	2.0	심방세동(8.8%), 심부전(8.6%), COPD(8.0%)
Tier 3	사망률 2~5%	1.5	고혈압(4.0%), 당뇨(4.7%), 협심증(2.7%)

6.1.5 학습 결과 (20 에포크)

지표	값
Macro AUROC	0.814
Tier 1 (사망률 $\geq 10\%$)	0.809
Tier 2 (사망률 5~10%)	0.844
Tier 3 (사망률 2~5%)	0.721
옵티마이저	AdamW lr=1e-4, weight_decay=1e-4
스케줄러	OneCycleLR max_lr=1e-4, warmup 10%, cosine decay
Gradient clipping	max_norm=1.0
Batch size	64

6.1.6 Threshold 정책 — 놓침방지 우선

초기 PR-curve 기반 최적값(0.001~0.06)에서 alert fatigue 문제로 인해 임상적으로 유의한 고정값(0.30/0.40/0.45)으로 전환했다.

Tier	Threshold	임상 의미
Tier 1	0.30	30% 의심만 떠도 alert (놓침 최소화)
Tier 2	0.40	어느 정도 확신할 때
Tier 3	0.45	확실할 때만

6.2 CXR 모달 — UNet + DenseNet-121

6.2.1 3-Layer 아키텍처

Layer	역할	출력
L1 UNet 세그멘테이션	폐 영역 분할 → CTR / CP angle / 폐면적비 / 기관편위 / 횡격막 측정	Mask + 정량 측정값
L2 DenseNet-121 분류	CheXpert 14-label → 6-disease multi-label 확률	확률 dict
L3 임상 로직	DenseNet × UNet 교차검증 → severity / risk_level → findings_text + impression	자연어 소견

6.2.2 6-disease Threshold (Youden 최적화)

질환	한글	Threshold	Critical 조건
Cardiomegaly	심비대	0.55	CTR > 0.60 + Edema 동반
Pleural Effusion	흉수	0.45	CP angle 둔화
Edema	폐부종	0.35	Cardiomegaly 동반 → CRITICAL
Pneumothorax	기흉	0.50	기관 반대측 편위 → 긴장성 기흉 → CRITICAL
Atelectasis	무기폐	0.50	—
Enlarged CM	심종격동 확대	0.45	—

6.2.3 측정 기준 (UNet 산출)

측정값	정상	Moderate	Severe	임상 의미
CTR (심흉비)	≤ 0.50	0.50~0.55	≥ 0.60	심비대 정량
CP angle	≤ 30°	30~90°	≥ 120°	흉수 둔화 정도
폐면적비	0.85~1.15	—	—	자세 검증
기관 편위	중심선	—	반대측 이동	긴장성 기흉 감지

6.2.4 성능 및 특징

- M1 Mac CPU 기준 150~300ms/장 추론

- Aurora ops_modal_results 에 mask_base64 + heatmap 자동 저장 (법적방어)
- Lateral view 감지 시 Stage1 에서 조기 종료 → 오판 방지
- 총 모델 파일 크기: UNet 84MB + DenseNet 28MB = 112MB

6.3 Lab 모달 — Rule Engine + XGBoost 예후

6.3.1 Stage A → B → C 3 단계 처리

Stage	역할	처리 내용	출력
Input	L1 입력 처리	약어 30+ 확장 (cp=chest pain, sob, dka, ...) + 7 Profile 매핑	정제된 입력 + Profile
Stage A	L2-A Critical	11 개 Critical Flag 점검 (주호소 무관)	즉시 critical findings
Stage B	L2-B Complaint	Profile 별 우선 검사 평가	고우선 findings
Stage C	L2-C Fullscan	나머지 항목 일반 평가	보조 findings
Report	L3 보고서	risk_level + cross_modal_hints + lab_summary	최종 응답
+α	Prognosis	XGBoost 5-라벨 (HbCrK·Lactate·Troponin) 6 시간 예측	악화 확률

6.3.2 11 개 Critical Flag (thresholds.py)

Flag	임계	임상 의미	즉시 조치
K > 6.5	mEq/L	고칼륨 → 심정지 위험	ECG + Ca gluconate
K < 2.5	mEq/L	저칼륨 → 부정맥	KCl 보충
Na < 120	mEq/L	심한 저나트륨 → 경련	3% saline
Glucose > 500	mg/dL	DKA	인슐린
Glucose < 40	mg/dL	심한 저혈당	즉시 D50
Lactate > 4.0	mmol/L	쇼크	Fluid resuscitation

Flag	임계	임상 의미	즉시 조치
Hb < 7	g/dL	심한 빈혈	Type & Cross
Plt < 20	10 ⁹ /L	출혈 위험	Platelet 수혈
Troponin > 0.04	ng/mL	NSTEMI 의심	Cath lab 호출
NT-proBNP > 1800	pg/mL	심부전 active	이노제
CK-MB > 25	ng/mL	심근 손상	심장내과

6.3.3 7 Chief Complaint Profile

Profile	대표 주호소	필수 panel	관련 중증질환
CARDIAC	흉통·실신·두근거림	Troponin, CK-MB, BNP, D-dimer, 전해질	심근경색, 폐색전
SEPSIS	발열·오한·의식저하	CBC, CRP, Procalcitonin, Lactate, 혈액배양	패혈증
RESPIRATORY	호흡곤란·기침	ABG, BNP, D-dimer, CBC	심부전, 폐색전
RENAL	부종·땀·고혈압	BUN, Cr, eGFR, 전해질	AKI, CKD
GI	복통·구토·흑변	CBC, LFT, Lipase, Amylase, Lactate	췌장염, GI 출혈
NEUROLOGICAL	두통·의식저하·경련	Glucose, 전해질, Ammonia, Tox	뇌졸중, 중독
GENERAL	비특이·외상	CBC, Coag, LFT, 전해질, Type&Cross	외상, 빈혈

6.4 Note RAG — Bedrock Claude Haiku/Sonnet

6.4.1 모델 설정

항목	값	비고
LLM 기본	anthropic.claude-3-haiku-20240307-v1:0	85~90% 케이스, 비용 최소화
LLM 복잡	us.anthropic.claude-sonnet-4-20250514-v1:0	10~15% multi-critical 케이스
max_tokens	4096	—

항목	값	비고
temperature	0.2	재현 가능성 우선
RAG 본체	Data-RAG Stack (ECS 별도)	FAISS + MIMIC-NOTE corpus

6.4.2 Retrieval Query 8000 자 예산 분배

섹션	char limit	비고
patient_summary	800	환자 식별 + 기본 정보
chief_complaint	600	주호소
vitals	800	V/S + 트리아지
cxr	1600	CXR findings + impression
lab	2200 (최대)	Lab 정량 데이터 → 최대 할당
ecg	1200	ECG findings + ECG vitals
other / search_intent	800	—
합계	8000	Bedrock 비용-품질 균형

6.4.3 9-Section SYSTEM PROMPT 9 원칙 (법적방어 핵심)

#	원칙
①	제공된 정보만 근거로 작성 (hallucination 금지)
②	미 실시 검사를 정상으로 간주 금지
③	RAG 는 참고 근거로만 사용
④	불확실한 경우 "가능성/감별 필요" 표현
⑤	의료진 참고용 보조 소견 명시
⑥	ICD-10 코드 함께 표기
⑦	응급도(KTAS) 명시
⑧	권장 조치는 행동 가능한 수준으로
⑨	모든 인용은 source 식별자(study_id) 첨부

6.4.4 9-Section 한국어 소견서 구성

섹션	내용
1. 환자 식별	이름, 나이, 성별, 환자번호
2. 주증상	트리아지 입력
3. 현병력 (HPI)	발병 시각·양상·동반 증상
4. 과거력 (PMHx)	기왕력·투약·알레르기
5. 진찰 소견	V/SKTAS·Physical Exam
6. 검사 소견	CXR + ECG + Lab 통합 인용
7. RAG 참고 근거	MIMIC-NOTE 유사 사례 (source 첨부)
8. 진단명 (A)	ICD-10 + 감별진단
9. 치료 계획 (P)	전원/입원/처치/추적

6.5 Central Hybrid Decision Engine

ML-First + Chief Complaint Map Prior 하이브리드. 첫 모달 선택부터 추가 모달 결정(최대 3 loop), Bedrock reasoning, 최종 GENERATE_REPORT 까지 진행. 하드코딩 룰 없음.

컴포넌트	역할
hybrid_decision_engine.py	ML + CC Map Prior fusion, 4 단계 confidence
bedrock_client.py	Claude Sonnet 4.5 reasoning
report_generator.py	RAG-svc HTTP 위임
models_stratified/initial/	첫 모달 선택 ML pickles
models_stratified/followup/	추가 모달 결정 ML pickles
orchestrator_utils/ cc_map.py	Chief Complaint historical prior

7. 백엔드·인프라

7.1 마이크로서비스 구성

본 시스템은 7개 핵심 서비스 + 1개 풀백 라우터의 마이크로서비스 아키텍처로 구성된다. 각 서비스는 독립 컨테이너 + 독립 ECS Service + 독립 IAM Role + 독립 LogGroup 을 가져 장애 격리·독립 배포·권한 분리·로그 추적성의 4 축을 동시 만족한다.

#	서비스	포트	기술 스택	주요 역할	외부 노출
1	orchestrator (Central)	8000	FastAPI + asyncio.gather + HAPI FHIR	능동형 모달 라우팅 + 9 섹션 소견서	ALB /orchestrator/*
2	ecg-svc	8001	FastAPI + ONNX Runtime (S6 Mamba)	12-lead ECG 24-disease 분류	내부 전용
3	cxr-svc	8002	FastAPI + ONNX (DenseNet+UNet)	흉부 X-ray 6-disease + 폐 세그멘테이션	내부 전용
4	lab-svc	8003	FastAPI + Rule Engine + XGBoost	3-Stage Lab 평가 + 6 시간 예측	내부 전용
5	rag-svc (Note RAG)	8000	FastAPI + Bedrock Runtime + ChromaDB	유사 사례 검색 + 소견서 생성 + DB 저장	내부 전용
6	router-svc	8004	FastAPI Stateless 프록시	Central 장애 시 풀백 라우팅	ALB /route/*
7	HAPI FHIR Server	8080	Java + Spring Boot + HAPI FHIR R4	FHIR 표준 자원 저장·조회	내부 전용 (EC2)
+	Web/Mobile FE	-	React 18 / Flutter	의사 모니터링 + 모바일 알림	CloudFront

7.2 핵심 API 명세 요약

각 서비스의 주요 API 는 OpenAPI 3.0 Swagger 형식으로 `/docs` 경로에 자동 게시된다. 본 섹션은 핵심 엔드포인트만 요약하며 전체 명세는 부록 B 를 참조한다.

7.2.1 Central Orchestrator

Meth od	Path	Request	Response	함의
POST	/api/triage	patient + chief_complaint + V/S + KTAS	encounter_id + ai_recommended_modal	트리아지 진입
GET	/api/encounter/{id}	encounter_id	current state + modal results + report	환자 상태 조회
WS	/ws/encounter/{id}	(WebSocket)	실시간 임상 알림 stream	Critical event push
POST	/api/encounter/{id}/ sign	physician_id + biometric_token	DocumentReference + signature_hash	Face ID 서명

7.2.2 Modal Services (ECG/CXR/Lab)

Service	Path	Request	Response (주요 키)	Latency p95
ecg-svc	POST /predict	wfdb_path + age + sex	diseases (24-label probs) + confidence + tier1_flags	< 1.0 초
cxr-svc	POST /predict	image_path + view	predictions (6- label) + measurements + severity + mask_base64	< 1.5 초
lab-svc	POST /evaluate	lab_values (dict) + chief_complaint	critical_flags + risk_level + cross_modal_hints	< 50ms
lab-svc	POST /predict_6h	lab_values + history	deterioration_prob (Hb/Cr/K/Lactate/Trop)	< 200ms

7.2.3 Note RAG (rag-svc)

Meth od	Path	Request	Response
POST	/query	patient_context + modal_results	Top-K similar cases + scores

Meth od	Path	Request	Response
POST	/generate	patient_context + modal_results + retrieval_results	report (9 sections) + sources + saved_to_aurora
GET	/health	(none)	OK + ChromaDB ready + Bedrock reachable

7.2.4 router-svc (폴백)

Central 장애 시 ALB 가 `/route/\*` 경로로 트래픽을 router-svc 에 우회한다. router-svc 는 판단·DB
저장을 수행하지 않고 모달 호출 + RAG 전달만 담당하는 stateless 프로크시다.

Meth od	Path	동작
POST	/route/predict	ECG/CXR/Lab 병렬 호출 → 결과 단순 집계
POST	/route/generate	위 결과를 rag-svc 에 전달 → 소견서 반환

7.3 AWS 네트워크

담당: 양정인

7.3.1 VPC 구성도 — 4-Tier × 2-AZ × 8 Subnet

본 시스템의 네트워크는 `say2-6team-vpc` (10.0.0.0/16) 를 기반으로 ap-northeast-2(서울) 리전
의 AZ-a / AZ-c 2개 가용영역에 4-Tier 8-Subnet 구조로 설계되었다. 가용영역 단일 장애 시에도
모든 계층의 트래픽 흐름이 유지되도록 모든 Tier 를 2-AZ 에 동일 배치했다.

Tier	AZ-a	AZ-c	CIDR	인터넷 라우 트	주요 자원
Public	public-subnet- a	public-subnet- c	10.0.0.0/24 · 10.0.1.0/24	IGW 0.0.0.0/0	ALB, HAPI FHIR EC2
Private App	private-app- subnet-a	private-app- subnet-c	10.0.10.0/24 · 10.0.11.0/24	없음	ECS Fargate 6 서비스
Private Data	private-data- subnet-a	private-data- subnet-c	10.0.20.0/24 · 10.0.21.0/24	없음	Aurora Serverless v2
Endpoint	endpoints- subnet-a	endpoints- subnet-c	10.0.30.0/24 · 10.0.31.0/24	없음	Interface VPC Endpoint ENI

7.3.2 서브넷 분리 설계 근거 — NAT-Free Architecture

본 시스템은 **NAT Gateway** 를 의도적으로 생성하지 않는다. Private App / Data / Endpoint 서브넷은 기본 인터넷 라우트가 부재하므로, 외부 통신은 모두 **VPC Endpoint(PrivateLink)** 를 경유한다. 이는 비용·보안·SaMD 적합성 3 가지 측면에서 동시에 유리한 설계 선택이다.

서브넷 Tier	분리 근거	보안 함의
Public	외부 진입점만 격리 (ALB·HAPI FHIR) — 환자 데이터는 절대 상주하지 않음	TLS 종단점 한정
Private App	ECS Fargate Task 전용 — 인터넷 outbound 차단으로 데이터 유출 경로 봉쇄	SaMD 추적성 보장
Private Data	Aurora Serverless v2 단독 — DB 직접 인터넷 노출 불가	HIPAA Equivalent 적합
Endpoint	Interface VPC Endpoint ENI 전용 — AWS API 호출만 PrivateLink 로 한정	트래픽이 AWS 백본을 벗어나지 않음

NAT Gateway 미생성으로 인한 비용 절감은 ap-northeast-2 기준 시간당 $\$0.059 \times 24h \times 30d \approx \$42/\text{월}$ 이며, 여기에 데이터 처리 요금($\$0.059/\text{GB}$)이 추가로 발생하지 않아 실제 절감 효과는 월 **\$50~80** 수준으로 추정된다.

7.3.3 Internet Gateway · Route Table 흐름

Route Table 은 AZ 별로 독립적으로 생성(총 7 개: Public 1 + App 2 + Data 2 + Endpoint 2)되어 향후 AZ 별 라우팅 차별화(예: AZ-c 전용 VPC Peering)에 대비한다.

Route Table	연결 Subnet	Destination — Target	함의
public-rt	Public A/C	0.0.0.0/0 — IGW · 10.0.0.0/16 — local	ALB 만 외부 노출
app-rt-a, app-rt-c	Private App A/C	10.0.0.0/16 — local · S3 — pl-78a54011 (Gateway EP)	인터넷 outbound 없음
data-rt-a, data-rt-c	Private Data A/C	10.0.0.0/16 — local · S3 — pl-78a54011	DB 는 outbound 자체 차단
endpoints-rt-a, endpoints-rt-c	Endpoint A/C	10.0.0.0/16 — local	Interface EP ENI 호스팅 전용

7.3.4 Route 53 + CloudFront + ALB + Cloud Map — 4-Layer 라우팅 토폴로지

사용자 요청은 글로벌 DNS부터 내부 서비스 디스커버리까지 4계층 라우팅을 거친다. 외부 트래픽은 CloudFront 217 PoP에서 캐싱·WAF·TLS 종단을 처리하고, 내부 서비스 간 통신은 Cloud Map 사실 DNS(*.say2-6team.local)로 추상화된다.

계층	자원	역할	라우팅 키
L1 — Global DNS	Route 53 (DNSSEC + Health Check)	도메인 → CloudFront 분산 + 가용성 점검	A/AAAA Alias
L2 — Edge CDN	CloudFront (217 PoP)	TLS 1.3 종단 · /static/* S3 캐싱 · WAF 전치	Behavior Path Pattern
L3 — Regional LB	ALB (internet-facing)	/orchestrator/* · /route/* Host/Path 기반 분기	Listener Rule (우선순위 5, 10)
L4 — Service Discovery	Cloud Map (say2-6team.local)	ECS Task IP 자동 갱신 + 사실 DNS A 레코드 (TTL 60s)	<svc>.say2-6team.local:<port>

외부 트래픽 흐름: 의사 브라우저 → Route 53 → CloudFront → WAF → ALB → ECS Task

내부 트래픽 흐름: orchestrator-svc → Cloud Map DNS → ecg/cxr/lab/rag-svc (asyncio.gather 병렬)

7.3.5 VPC Endpoint — PrivateLink 8 종 + NAT 비용 절감

NAT Gateway를 대체하기 위해 Gateway EP 1종 + Interface EP 7종 총 8개의 VPC Endpoint를 배치한다. Interface EP는 AZ-a / AZ-c Endpoint 서브넷에 ENI를 분산 배치하여 단일 AZ 장애에도 AWS API 호출이 유지된다.

VPC Endpoint	Type	용도	비용 모델	대체 NAT 비용 절감
S3	Gateway	모델 ONNX·CXRPNG·ChromaDB 다운로드	무료 (Gateway EP)	매우 큼 (대용량 파일)
Bedrock Runtime	Interface	Claude Haiku/Sonnet 호출 (소견서 생성)	\$0.014/h × 2 AZ + 데이터 처리	큼
Bedrock Agent Runtime	Interface (조건부)	Agent 기능 활성화 시에만 생성	—	—
Secrets Manager	Interface	Aurora 자격증명·FCM 키 동적 참조	\$0.014/h × 2 AZ	중간
KMS	Interface	Customer	\$0.014/h × 2 AZ	중간

VPC Endpoint	Type	용도	비용 모델	대체 NAT 비용 절감
		Managed Key Decrypt API		
CloudWatch Logs	Interface	6 개 서비스 Log 전송	\$0.014/h × 2 AZ	큼 (실시간 스트림)
ECR API	Interface	이미지 메타데이터 조회	\$0.014/h × 2 AZ	큼 (Task 시작마다)
ECR Docker	Interface	이미지 레이어 다운로드	\$0.014/h × 2 AZ	매우 큼 (cxr-svc 8GB)

Interface EP 7 종 × 2 AZ × \$0.014/h ≈ **\$141/월** 고정비가 발생하지만, 동일 트래픽을 NAT Gateway 로 처리할 경우 \$50~80 고정비 + 데이터 처리 \$0.059/GB 가 추가되며, ECR 이미지 풀 (특히 cxr-svc 8GB × 빈번한 배포)과 CloudWatch Logs 스트림 트래픽을 고려하면 PrivateLink 가 약 **30~40%** 더 저렴할 뿐 아니라 트래픽이 AWS 백본을 벗어나지 않아 SaMD 추적성·법적방어 측면에서 우월하다.

7.3.6 DNS 전략 — *.say2-6team.local 사설 디스커버리

ECS Fargate 는 Task 재시작 시 ENI IP 가 변경되므로 IP 기반 통신이 불가능하다. 본 시스템은 AWS Cloud Map Private DNS Namespace 를 사용하여 모든 내부 서비스에 고정 DNS 를 부여한다.

서비스	사설 DNS	포트	호출 경로
orchestrator	orchestrator.say2-6team.local	8000	ALB → orchestrator (외부 진입)
ecg-svc	ecg-svc.say2-6team.local	8001	orchestrator → ecg (병렬)
cxr-svc	cxr-svc.say2-6team.local	8002	orchestrator → cxr (병렬)
lab-svc	lab-svc.say2-6team.local	8003	orchestrator → lab (병렬)
rag-svc	rag-svc.say2-6team.local	8000	orchestrator → rag (소견서 생성)
router-svc	router-svc.say2-6team.local	8004	ALB → router (폴백)

Cloud Map 은 ECS Service Connect 와 통합되어 Task 등록 시 자동으로 A 레코드를 갱신(TTL 60 초)하며, 'HealthCheckCustomConfig: FailureThreshold=1'로 unhealthy Task 를 즉시 DNS 에서 제거한다.

7.3.7 ALB Target Group + Listener Rule — Path-Based Routing

ALB 는 외부 진입점이 필요한 2개 서비스(orchestrator, router-svc)만 노출하고, 모달 서비스(ecg/cxr/lab/rag)는 ALB Target Group 을 의도적으로 생성하지 않아 외부에서 접근 불가하다.

Target Group	Port	Health Check	Listener Rule	우선순위
orchestrator-tg	8000	GET /health (200) · 30s · Threshold 2/3	/orchestrator/* → forward	10
router-svc-tg	8004	GET /health (200) · 30s · Threshold 2/3	/route/* → forward	5
(modal services)	—	—	미생성 (내부 전용)	—

`/route/\*` Rule 을 더 높은 우선순위(5)로 둔 이유는 orchestrator 장애 시 router-svc 로의 폴백 경로가 우선적으로 매칭되어야 BCP/DR 요구사항(7.8 절)을 충족하기 때문이다.

7.3.8 CloudFront 캐시 정책 + Origin Failover

Behavior	Path	Origin	Cache TTL	합의
Static	/static/*	S3 (정적 HTML/JS/CSS)	1 년 (immutable hash 파일명)	React Vite 빌드 결과물
API	/orchestrator/*	ALB	0 초 (캐시 비활성화)	환자별 동적 응답
Fallback	/route/*	ALB	0 초	폴백 라우터
WAF	(전 경로)	—	—	OWASP Top 10 · Geo-blocking

Origin Failover 는 ALB Origin Group 을 구성하여 5xx 응답 발생 시 보조 Origin(향후 ap-northeast-1 도쿄 리전 ALB · Phase 3)으로 자동 전환하도록 설계되어 있다.

7.3.9 VPC Flow Logs — 90 일 감사 추적

전체 VPC 트래픽은 S3 Bucket(`say2-6team-vpc-flow-logs-<account>-<region>`)에 60 초 집계 주기로 저장되며, 29 개 필드(srcaddr, dstaddr, action, traffic-path, pkt-src-aws-service 등)의 확장 포맷으로 기록된다. 90 일 자동 삭제 정책으로 비용을 통제하면서도 SaMD 감사 요구사항(최소 1 년의 부분 기간)을 만족한다. `BucketOwnerEnforced` + `BlockPublicAccess` + AES256 암호화로 감사 로그 자체의 무결성을 보장한다.

7.3.10 다이어그램

전체 네트워크 토폴로지는 본 보고서 그림 5-1 「EMON Med® 전체 시스템 아키텍처」를 참조한다. CloudFront → WAF → ALB → ECS Cluster → Modal Services → Aurora · S3 · Bedrock 의 전 계

총 트래픽 흐름이 색상별 범례(사용자 트래픽 / AI 추론 / 데이터 저장·조회 / 보안인증 / 모니터링·알림 / RAG임베딩)로 구분되어 있다.

참고 문서: AWS/AWS_Network_Design_v1.md, CloudFormation: network-stack.yaml

7.4 AWS 컴퓨팅

담당: 이정인

7.4.1 ECS Fargate Cluster — GPU-Free Serverless Container

본 시스템은 `say2-6team-ecs-cluster` 단일 ECS 클러스터에 6개 마이크로서비스(orchestrator, ecg-svc, cxr-svc, lab-svc, router-svc, rag-svc)를 FARGATE + FARGATE_SPOT 하이브리드 런타임으로 운영한다. 기본 Task는 11개(5개 서비스 × 2 + rag-svc × 1)이며, Auto Scaling으로 최대 20개+까지 확장된다.

GPU-Free 설계 근거

선택 근거	상세
Fargate 는 GPU 인스턴스 부착 불가	EC2 g4dn 등 GPU 사용 시 ECS EC2 launch type 필요 → 서버리스 이점 상실
CPU 추론 친화적 모델 구성	S6 Mamba(9M 파라미터) ONNX·UNet+DenseNet(112MB)·XGBoost·Rule Engine 모두 CPU 충분
운영 부담 최소	OS 패치·호스트 관리·보안 업데이트 모두 AWS 위임 (SaMD 추적성 보존)
Task 단위 격리	모달별 라이브러리 충돌(PyTorch vs ONNX vs LightGBM) 완전 차단
비용 효율	추론 시간 대비 GPU 유휴 비용 회피 — 비용 70%↓ (10.2.2 절)

스택 배포 순서는 의존성 그래프에 따라 **network-stack** → **security-stack** → **aurora-stack** → **compute-stack**으로 진행된다.

7.4.2 서비스별 Task Definition — vCPU / Memory 할당

각 서비스는 모델 크기·동시 로드 수·추론 워크로드 특성에 따라 차등 할당된다. 특히 **cxr-svc**는 **DenseNet**(분류) + **UNet**(세그멘테이션) 두 모델을 동시 로드하기 때문에 최대 리소스(2 vCPU / 8 GB)가 할당된다.

서비스	vCPU	Memory	Port	Task Role	ALB 노출
orchestrator	0.5 (512)	1 GB (1024)	8000	orchestrator-task-role	✅ /orchestrator/*
ecg-svc	1 (1024)	2 GB (2048)	8001	ecg-task-role	❌ 내부 전용
cxr-svc	2 (2048)	8 GB (8192)	8002	cxr-task-role	❌ 내부 전용

서비스	vCPU	Memory	Port	Task Role	ALB 노출
lab-svc	1 (1024)	2 GB (2048)	8003	lab-task-role	❌ 내부 전용
router-svc	0.25 (256)	0.5 GB (512)	8004	router-task-role	✅ /route/*
rag-svc	0.5 (512)	1 GB (1024)	8000	rag-task-role	❌ 내부 전용

서비스 분리 4 대 이유

#	이유	임상적 함의
1	기술 스택 격리 — PyTorch(ECG) · ONNX(CXR) · LightGBM(Lab) 라이브러리 충돌 차단	한 모달 의존성 업그레이드가 타 모달 영향 없음
2	독립 스케일링 — 특정 모달 트래픽 폭주 시 해당 서비스만 확장	야간 ECG 집중 시 ecg-svc 만 6 Task 로 확장
3	장애 격리 — 한 서비스 다운 시에도 나머지 모달은 정상 동작	CXR 장애 시에도 ECGLab 으로 의사결정 가능 (Fail-Safe)
4	독립 배포 — 특정 모달만 교체·롤백 가능	S6 Mamba weights 업데이트 시 cxr/lab 은 무중단

7.4.3 Auto Scaling 정책 — CPU Target Tracking

모든 ECS Service 는 Application Auto Scaling 으로 CPU 사용률 기반 Target Tracking 을 적용한다. Scale-out cooldown 은 60 초로 짧게(빠른 트래픽 대응), Scale-in cooldown 은 300 초로 길게(cold start 피크 회피) 설정하여 응급 상황 응답성과 안정성을 동시에 확보한다.

서비스	Baseline	Max	CPU Target	Scale-out CD	Scale-in CD
orchestrator	2	4	60%	60 초	300 초
ecg-svc	2	6	70%	60 초	300 초
cxr-svc	2	6	70%	60 초	300 초
lab-svc	2	4	60%	60 초	300 초
router-svc	2	(고정)	—	—	—
rag-svc	2	(고정)	—	—	—

Deployment Configuration: 모든 서비스 `MinimumHealthyPercent: 50` + `MaximumPercent: 200` 으로 Rolling Update 시에도 무중단 배포가 보장된다.

7.4.4 Multi-AZ 분산 전략 — AZ-a + AZ-c

모든 ECS Service 는 Private App Subnet AZ-a (10.0.10.0/24) + AZ-c (10.0.11.0/24)에 Task 를 분산 배치한다. `AssignPublicIp: DISABLED`로 모든 Task 는 사실 IP 만 보유하여 인터넷 직접 접근이 차단된다.

항목	구현
기본 Task = 2 의미	AZ-a × 1 + AZ-c × 1 (ECS placement strategy spread)
AZ 장애 시 거동	unhealthy Task 가 30 초 내 정상 AZ 에서 자동 재시작 → 다른 AZ Task 가 100% 트래픽 처리
ALB Cross-Zone LB	활성화 — 트래픽이 두 AZ 에 균등 분산
Cloud Map 자동 갱신	재시작된 Task 의 새 IP 를 60 초 TTL DNS 에 즉시 반영

7.4.5 HAPI FHIR EC2 t4g.medium — 단일 인스턴스 운영 근거

FHIR R4 표준 서버인 HAPI FHIR 는 ECS Fargate 가 아닌 EC2 t4g.medium 단일 인스턴스로 운영한다. 이는 의도적인 설계 선택으로, 다음의 트레이드오프 분석에 기반한다.

요소	EC2 t4g.medium 선택 이유
워크로드 특성	HAPI FHIR 는 무거운 Java 기반 + JVM warm-up 30~60 초 → 잦은 재시작 비적합
동시 요청 패턴	응급실 단일 환자당 FHIR 호출은 burst 후 idle — Spring Boot persistent state 유리
비용	t4g.medium ARM Graviton2 약 \$25/월 vs Fargate 동급 vCPU/Mem 약 \$60/월 → 58% 절감
데이터 정합성	PostgreSQL 백엔드(Aurora central_db hapi schema) 직결 — connection pool 재사용 유리
한계 인정	단일 AZ 운영으로 SPOF 존재 → Phase 2 에서 Multi-AZ EC2 + ALB 백엔드로 승격 예정

ECS Task 에는 `FHIR\_BASE\_URL=http://10.0.0.107:8080/fhir` 환경변수로 EC2 사실 IP 가 주입되며, 향후 Cloud Map / Route 53 사실 DNS 로 추상화 예정이다.

7.4.6 ECR 이미지 빌드·푸시 자동화 — build-and-push.sh

6개 서비스의 컨테이너 이미지는 Amazon ECR 의 동일 계정 레지스트리에 저장되며, `build-and-push.sh` 스크립트로 빌드·태깅·푸시가 자동화된다. ECR 이미지 풀은 ECR API + ECR Docker VPC Endpoint 를 경유하여 NAT 없이 사실 네트워크 내부에서 완료된다.

단계	내용
1. Login	<code>aws ecr get-login-password docker login --username AWS --password-stdin</code>

단계	내용
	<account>.dkr.ecr.ap-northeast-2.amazonaws.com
2. Build	docker build -t <svc>:latest . (서비스별 Dockerfile, multi-stage)
3. Tag	docker tag <svc>:latest <ecr-uri>:<git-sha> + :latest
4. Push	docker push <ecr-uri>:<git-sha> → ECR API EP 경유
5. Deploy	CloudFormation *ImageUri 파라미터에 새 태그 주입 → ECS Service Rolling Update

이미지 태그는 불변(**immutable**) **Git SHA** + 가변(**latest**) 듀얼 태그 정책으로, 롤백 시 정확한 SHA 로 즉시 복구 가능하다.

7.4.7 ALB Health Check + ECS Container Health Check — 이중 감시

각 서비스는 두 계층의 헬스체크로 이중 감시된다. ALB Health Check(L7)가 트래픽 분배 차원에서 unhealthy Task 를 격리하고, ECS Container Health Check(컨테이너 내부)가 Task 자체의 재시작을 트리거한다.

서비스	ALB HC	Container HC	StartPeriod
orchestrator	GET /health · 30s · Threshold 2/3	urllib.request.urlopen('http://localhost:8000/health')	10s
ecg-svc	(ALB 비노출)	GET /health · 30s · 3 retries	60s (ONNX 로드 대기)
cxr-svc	(ALB 비노출)	GET /healthz · 30s · 3 retries	60s (DenseNet+UNet 로드 대기)
lab-svc	(ALB 비노출)	GET /health · 30s · 3 retries	10s
router-svc	GET /health · 30s · Threshold 2/3	GET /health · 30s · 3 retries	10s
rag-svc	(ALB 비노출)	GET /health · 30s · 3 retries	120s (ChromaDB S3 다운로드 ~30s + warm-up)

특히 모델 로드가 무거운 서비스(ECG·CXR·RAG)는 StartPeriod 를 60~120 초로 길게 설정하여 cold start 중 false-unhealthy 판정으로 인한 무한 재시작 루프를 방지한다.

7.4.8 Bedrock Haiku/Sonnet 동적 라우팅 비용 효과

rag-svc 는 AWS Bedrock 을 통해 두 가지 Claude 모델을 동적으로 호출한다.

모델	Model ID	케이스 비중	단가 (입력/출력 1M 토큰)
Haiku (기본)	anthropic.claude-3-haiku-20240307-v1:0	85~90%	\$0.25 / \$1.25
Sonnet 4 (복잡)	us.anthropic.claude-sonnet-4-20250514-v1:0	10~15%	\$3.00 / \$15.00

라우팅 로직: Critical Flag 다중 발생 / 모달 결과 충돌 / Confidence < MEDIUM 케이스에 한해 Sonnet 으로 escalation. Sonnet 전용 사용 대비 비용 약 80% 절감(Haiku 1 토큰당 단가가 Sonnet 의 1/12)이 추정되며, 의료 자문급 추론이 필요한 케이스만 선별적으로 Sonnet 을 활용함으로써 품질과 비용을 동시에 최적화한다. Bedrock Runtime 호출은 VPC Endpoint/PrivateLink를 경유하여 모든 환자 데이터가 AWS 백본을 벗어나지 않는다.

7.4.9 컨테이너 리소스 사용 모니터링 결과

서비스	CPU 평균	CPU Peak	Memory 평균	Memory Peak	합의
orchestrator	15%	55%	480 MB	720 MB	0.5 vCPU / 1 GB 적정
ecg-svc	35%	78%	1.3 GB	1.8 GB	1 vCPU / 2 GB 적정
cxr-svc	45%	85%	5.2 GB	7.1 GB	2 vCPU / 8 GB 적정 — 모델 2 개 동시 로드
lab-svc	8%	22%	380 MB	520 MB	1 vCPU / 2 GB 여유
router-svc	5%	18%	180 MB	260 MB	0.25 vCPU / 0.5 GB 적정 (Stateless 프록시)
rag-svc	18%	60%	720 MB	920 MB	0.5 vCPU / 1 GB 적정

7.4.10 월간 인프라 비용 (서울 리전 Baseline)

항목	사양	월 비용
orchestrator (×2 Task)	0.5 vCPU / 1 GB	~\$58

항목	사양	월 비용
ecg-svc (×2 Task)	1 vCPU / 2 GB	~\$110
cxr-svc (×2 Task)	2 vCPU / 8 GB	~\$460
lab-svc (×2 Task)	1 vCPU / 2 GB	~\$110
router-svc (×2 Task)	0.25 vCPU / 0.5 GB	~\$29
rag-svc (×2 Task)	0.5 vCPU / 1 GB	~\$58
Fargate 합계	—	~\$825
HAPI FHIR EC2	t4g.medium	~\$25
Application Load Balancer	—	~\$25
CloudWatch Logs	6 LogGroup	~\$10
총 Baseline	—	~\$885/월

Auto Scaling 활성화 + FARGATE_SPOT 혼합 운영으로 비-피크 시간대 **20~30%** 추가 절감 여지가 있으며, 향후 ECGCXR-Lab 모델의 SageMaker Serverless Inference 전환을 통한 추가 최적화도 검토된다.

참고 문서: AWS/AWS_Compute_Design_v1.md, CloudFormation: compute-stack.yaml

7.5 AWS 보안

담당: 양정인

7.5.1 보안 설계 철학 — Defense-in-Depth × 의료 데이터 격리

본 시스템은 환자 진료기록과 AI 추론 결과를 다루는 SaMD Class I~II 후보 시스템으로, 단일 계층 방어가 아닌 Edge – Network – Compute – Data 4 계층 심층 방어(Defense-in-Depth)와 의료 데이터 외부 인터넷 의존도 최소화의 두 원칙을 동시 적용한다. 이는 식약처 SaMD 가이드라인의 추적성 요구와 개인정보보호법의 외부 유출 통제 요구를 만족하기 위한 설계 선택이다.

계층	방어 자원	차단 대상
L1 Edge	Route 53 DNSSEC + CloudFront TLS 1.3 + WAF	DDoS, OWASP Top 10, 봇, Geo 차단
L2 Network	VPC 3-tier + Security Group 9 종 + VPC Endpoint 8 종	횡 이동, 외부 egress
L3 Compute	IAM Task Role × 6 + Cognito + ECS Task 격리	권한 상승, 비인가 사용자

계층	방어 자원	차단 대상
L4 Data	KMS Customer Managed Key + Secrets Manager + Aurora 암호화	저장 데이터 유출, 자격증명 노출

7.5.2 Edge 보안 — Route 53 DNSSEC · CloudFront TLS 1.3 · WAF Managed Rules

자원	설정	보안 함의
Route 53	DNSSEC 활성화 · Health Check	DNS 캐시 포이즈닝 차단 + 가용성 점검
CloudFront	TLS 1.3 (Minimum Protocol Version) · HTTP→HTTPS 자동 리다이렉트	모든 환자 데이터 통신 암호화
ALB	HTTPS 443 (외부) · HTTP 8000/8004 (내부) · ACM 인증서	TLS 종단점 일원화
WAF	Regional Scope · ALB 직접 결합 · DefaultAction Allow	OWASP Top 10 · Rate Limit · IP 평판

WAF 는 AWS Managed Rule Group 3 종과 Rate-Based Statement 1 종의 총 4 개 룰로 구성되며, Phase 1 검증 기간에는 모든 룰을 **Count** 모드(차단 없이 로그만 수집)로 운영하여 정상 트래픽 패턴을 학습한 뒤 운영 진입 시 Block 으로 전환하는 점진적 보안 적용 방식을 채택했다.

WAF Rule	Priority	Mode	차단 대상
AWSManagedRulesCommonRuleSet	10	Count → Block	OWASP Top 10 (SQLi, XSS, RCE, LFI 등)
AWSManagedRulesKnownBadInputsRuleSet	20	Count → Block	CVE-known 악성 입력 패턴
AWSManagedRulesAmazonIpReputationList	30	Count → Block	AWS 위협 인텔리전스 IP 평판
RateLimitPerIP	100	Count → Block	IP 당 5 분 2,000 요청 초과 (DDoS 완화)

Geo-blocking 은 Phase 2 부터 의료기관 소재 국가(KR) 외 IP 차단 룰을 추가할 예정이며, 해외 환자 응급실 방문 케이스(외국인 노동자, 관광객) 대응을 위해 화이트리스트 기반 운영을 검토 중이다.

7.5.3 3-Tier 네트워크 분리 + Endpoint 보조 계층

7.3 절에서 상술한 VPC 토폴로지는 보안 관점에서 다음의 격리 효과를 제공한다.

Tier	보안 함의	차단되는 공격 시나리오
Public	외부 진입점만 격리(ALB·HAPI FHIR) — 환자 데이터 비상주	진입점 직접 침해 시에도 환자 데이터 도달 불가
Private App	ECS Fargate Task 전용 — 인터넷 outbound 차단	컨테이너 침해 시 외부 C2 서버 통신 차단
Private Data	Aurora 단독 — DB 직접 인터넷 노출 불가	외부에서 DB 직접 스캐닝/공격 불가
Endpoint	Interface VPC Endpoint ENI — AWS API 만 PrivateLink	모든 AWS 트래픽이 AWS 백본 내부 유지

NAT Gateway 미생성은 단순 비용 절감(7.3.2 절)이 아니라 의료 데이터 처리 서비스의 인터넷 직접 egress 경로 자체를 제거하는 보안 결정이다.

7.5.4 Security Group 9 종 매트릭스 — Stateful 화이트리스트

NACL(Stateless)보다 Security Group(Stateful) 중심의 화이트리스트 접근 제어를 우선한다. NACL 을 초기부터 강하게 적용하면 ALB Health Check, ECS/Fargate 통신, VPC Endpoint 접근, DB 연결에서 ephemeral port · return traffic 문제가 발생하므로, Phase 1 은 SG 중심으로 안정화 후 Data Subnet 중심의 NACL hardening 을 후속 적용한다.

Source SG	Destination SG	Port	목적	경로 유형
0.0.0.0/0	alb-sg	443	외부 HTTPS 진입	정상
alb-sg	central-sg	8000	ALB → orchestrator	정상
alb-sg	router-sg	8004	ALB → router (폴백)	Fail-Safe
central-sg	ecg-sg	8001	orchestrator → ECG	정상
central-sg	cxr-sg	8002	orchestrator → CXR	정상
central-sg	lab-sg	8003	orchestrator → Lab	정상
central-sg	rag-sg	8000	orchestrator → RAG	정상

Source SG	Destination SG	Port	목적	경로 유형
central-sg	hapi-sg	8080	orchestrator → HAPI FHIR	정상
central-sg	aurora-sg	5432	orchestrator → Aurora	정상
router-sg	ecg/cxr/lab/rag-sg	8001~8003, 8000	폴백 라우팅	Fail-Safe
ecg/cxr/lab-sg	aurora-sg	5432	모달 결과 직접 저장	정상
rag-sg	aurora-sg	5432	RAG → 소견서 저장	정상
hapi-sg	aurora-sg	5432	HAPI → FHIR 스키마	정상
모든 svc-sg	endpoints-sg	443	VPC Endpoint 호출	정상

핵심 설계 포인트: 정상 경로에서는 모든 서비스 간 호출이 orchestrator 를 중심으로 단방향으로 흐르고, 폴백 경로(router-svc)는 별도 SG 로 분리되어 장애 시에만 모달 서비스에 도달 가능하다. 모든 SG 는 `SecurityGroupEgress: []`로 시작하여 명시적 Egress Rule 만 허용하므로 우회 통신이 원천 차단된다.

7.5.5 KMS Customer Managed Key — At-Rest 암호화 기준

본 시스템은 `alias/say2-6team-kms-key` 단일 Customer Managed Key(CMK)를 프로젝트 공통 암호화 기준으로 운영하며, 자동 키 로테이션 활성화(EnableKeyRotation: true) + 삭제 보호 7일(PendingWindowInDays: 7)로 장기 운영 안정성을 확보한다.

암호화 대상	KMS 활용	합의
Secrets Manager (DB 자격증명, FCM 키)	KMS Decrypt API	Task 시작 시에만 평문 복호화, 메모리 거주
Aurora Serverless v2 (Storage)	Aurora 전용 KMS Key (aurora-stack)	Storage-level AES-256 암호화
S3 (모델 ONNX · 환자 CXR · ChromaDB)	SSE-KMS	객체별 KMS context 로 접근 제어
ECS Task Definition Secrets	KMS Decrypt (ECS Execution Role)	환경변수 평문 노출 방지
CloudWatch Logs	KMS Encrypt	로그 자체의 무결성 보장

Phase 2 향후 강화 — 환자 식별정보 별도 KMS Key

현재는 단일 CMK 로 운영하나, Phase 2 운영 진입 시 환자 식별정보(주민번호 hash, 이름)에 한해 별도 CMK 를 분리하여 키별 IAM Policy 로 접근을 최소화하고 CloudTrail KMS 접근 로그를 5년간 보존(개인정보보호법 처리 기록 요구 + SaMD 추적성)할 계획이다.

7.5.6 Secrets Manager — DB · API Key + 동적 참조

본 시스템은 환경변수에 평문 자격증명을 절대 저장하지 않는다. 모든 비밀정보는 Secrets Manager 에 저장되고, ECS Task Definition 은

`{{resolve:secretsmanager:<arn>:SecretString:<key>}}` 동적 참조 패턴으로 Task 시작 시점에만 복호화한다.

Secret	저장 내용	참조 서비스	Rotation
say2-6team/aurora-secret	Aurora master username · password	orchestrator, ecg, cxr, lab, rag, hapi	자동 90 일 (RDS managed)
say2-6team/fcm-credentials	FCM Service Account JSON	orchestrator	수동 (Google 발급 주기)
say2-6team/hapi-credentials	HAPI DB 사용자 (hapi_user)	HAPI FHIR EC2	수동

Aurora 자격증명은 RDS Secrets Manager 통합 기능으로 90 일 자동 로테이션되며, 이는 ISMS-P 인증 항목 중 「암호 정책 및 주기적 변경」 요구를 자동 충족한다. **Bedrock** 은 API Key 가 아닌 IAM Role 임시 자격증명(SigV4)으로 호출되어 별도 키 보관이 불필요하다.

7.5.7 IAM Role 최소권한 — Execution Role × 1 + Task Role × 6 분리

ECS 의 두 가지 IAM Role 을 명확히 분리한다. Execution Role 은 ECS 에이전트가 Task 를 시작·운영하기 위한 권한(이미지 풀, 로그 전송, 환경변수 비밀 복호화)이고, Task Role 은 컨테이너 내부 애플리케이션 코드가 AWS 서비스를 호출할 때 사용하는 권한이다. 6개 서비스마다 별도 Task Role 을 발급하여 한 서비스 침해 시에도 타 서비스 권한으로의 횡 이동을 차단한다.

Role	Sid	권한 범위
ecs-execution-role	ReadTaskDefinitionSecrets	secretsmanager:GetSecretValue on say2-6team/*
ecs-execution-role	DecryptTaskDefinitionSecrets	kms:Decrypt on 프로젝트 CMK + Aurora CMK
orchestrator-task-role	InvokeBedrockForOrchestration	bedrock:InvokeModel · InvokeModelWithResponseStream
orchestrator-task-role	ReadProjectSecrets + UseProjectKmsKey + S3 GetObject (prefix)	—

Role	Sid	권한 범위
ecg/cxr/lab-task-role	(Bedrock 권한 부재) + Secrets + KMS + S3 GetObject	모달은 LLM 호출 불필요 → 권한 축소
rag-task-role	InvokeBedrockForNarrativeGeneration + Secrets + KMS + S3	RAG 만 Bedrock 호출 가능
router-task-role	Secrets + KMS Decrypt 만 (S3Bedrock 부재)	Stateless 풀백, 최소 권한

핵심 격리 효과: ECG/CXR/Lab 모달 컨테이너는 침해되더라도 Bedrock 호출 권한이 없어 LLM 을 통한 데이터 유출 채널이 봉쇄되며, Router 는 S3Bedrock 권한이 모두 없어 풀백 경로가 침해되더라도 환자 데이터 직접 접근이 불가하다.

향후 최소권한 정교화 계획

단계	현재 (Phase 1)	목표 (Phase 2)
S3	arn:aws:s3:::say2-6team-* (prefix wildcard)	exact bucket ARN
Secrets	say2-6team/* (prefix wildcard)	exact secret ARN per service
Bedrock	Resource: "*" (model ID 변경 대응)	확정 모델 ARN (Claude Haiku/Sonnet)

7.5.8 Cognito 기반 사용자 인증 — 의료진 사번 기반

응급실 의사간호사 인증은 AWS Cognito User Pool 을 기준선으로 한다. 일반적인 이메일 기반 가입이 아닌 의료진 사번 또는 내부 식별자(예: DR001, NR001) 기반 username 로그인 구조를 채택하여 병원 조직 식별 체계와 정합한다.

항목	설정	의료 환경 적합성
Username	사번 (DR001 등) · email 은 AliasAttribute	조직 식별 체계 연동
AdminCreateUserOnly	true	자율 가입 차단 — 병원 관리자만 계정 발급
비밀번호 정책	최소 8 자 + 대·소문자 + 숫자 (특수문자는 권장)	NIST SP 800-63 호환
Access Token	1 시간	짧은 수명으로 탈취 영향 최소화
Refresh Token	30 일	—
MFA	(Phase 2 강제 활성화 예정)	ISMS-P 인증 의무 항목

항목	설정	의료 환경 적합성
custom:role	doctor / nurse / admin	RBAC 분기용
OAuth 2.0	Authorization Code Flow	SAML/OIDC SSO 확장 가능

SSO 확장 경로 (Phase 2): 병원 내부 Active Directory · 사내 SSO 환경 통합을 위해 `UserPoolIdentityProvider` (SAML 또는 OIDC type) 추가만으로 SSO 연동이 가능하도록 Pool 구조를 보존했다. JWT 토큰 검증은 ALB와 별개로 orchestrator FastAPI middleware에서 수행한다.

7.5.9 의료 인허가 대응 — ISMS-P + HIPAA Equivalent

ISMS-P 인증 대응 매핑

ISMS-P 통제 항목	본 시스템 대응
1.1 정책·조직	보안 정책 문서화 (AWS_Security_Design_v1.md)
1.2 위험 관리	위험 모델링 + WAF Count→Block 단계적 적용
2.1 인적 보안	Cognito + AdminCreateUserOnly + custom:role RBAC
2.5 운영 보안	SG 화이트리스트 + IAM 최소권한 + KMS 자동 로테이션
2.6 정보시스템 도입·개발·운영	CloudFormation IaC + GitHub PR 리뷰
2.7 암호 통제	TLS 1.3 (전송) + KMS AES-256 (저장) + Secrets Manager
2.8 접근 통제	9-SG 매트릭스 + Task Role 6 종 분리
2.9 운영 환경 보안	VPC Flow Logs 90 일 + CloudTrail (예정)
2.10 시스템·서비스 운영 관리	CloudWatch + X-Ray + 알림 SNS 토픽
2.12 재해 복구	Multi-AZ + Aurora 자동 백업 RPO 5 분 (7.8 절)
3.x 개인정보 처리 단계별 요구	환자 식별정보 별도 CMK(Phase 2) + Audit Log 5 년 보존

HIPAA Equivalent — 식약처 · 개인정보보호법 대응

미국 HIPAA에 대응되는 한국 규제는 개인정보보호법(특히 민감정보 처리 조항) + 의료법 + 식약처 SaMD 가이드라인의 3종 체계이며, 본 시스템은 다음의 기술적 통제로 대응한다.

HIPAA Security Rule (Reference)	한국 대응 규제	본 시스템 통제
Access Control (164.312(a))	개인정보보호법 §29 안전조치	Cognito + IAM Role 6 종 + SG 9 종

HIPAA Security Rule (Reference)	한국 대응 규제	본 시스템 통제
Audit Controls (164.312(b))	개인정보보호법 §29 접근기록 보관	VPC Flow Logs + CloudTrail + audit_log 테이블
Integrity (164.312(c))	의료법 §22 진료기록 무결성	KMS 서명 + DocumentReference Hash
Person/Entity Authentication (164.312(d))	의료법 §17 의료인 자격 확인	Cognito + Face ID 전자서명 (mobile)
Transmission Security (164.312(e))	개인정보보호법 §29 암호화 전송	TLS 1.3 종단 + VPC PrivateLink

7.5.10 보안 사고 대응 절차 (Runbook)

운영 중 보안 이벤트 발생 시 5 단계 즉시 대응 절차를 정의한다. 모든 단계는 5 분 내 1차 대응을 목표로 한다.

단계	트리거	자동 / 수동	조치	목표 시간
1. Detect	WAF Block 급증 · CloudWatch Alarm · GuardDuty Finding	자동	SNS → Slack #security-alert	즉시
2. Contain	비정상 IP 감지	자동 + 수동	WAF Rule 즉시 Block 전환 · SG 임시 차단	5 분 내
3. Eradicate	침해 컨테이너 식별	수동	ECS Task StopTask + 새 Task 배포	10 분 내
4. Recover	정상화 확인	자동 + 수동	ALB Health Check 정상화 + Aurora 트랜잭션 정합성 검증	30 분 내
5. Post-Mortem	사후 분석	수동	VPC Flow Logs + CloudTrail 추적 + Notion 보고서 작성	24 시간 내

핵심 보고 채널: 임상 영향 가능성이 있는 사고는 임상 알림 SNS 토픽(Critical Push)으로 즉시 의료진에게 전달되며, 운영 영향만 있는 사고는 운영 알림 SNS 토픽으로 개발팀 Slack 에 전달된다(7.7 절 모니터링 참조).

7.5.11 보안 설계의 한계 인식

한계	현재 (Phase 1)	개선 계획 (Phase 2~3)
WAF Count 모드	정상 트래픽 학습 중	검증 후 Block 전환
IAM Wildcard prefix	dev 통합 편의	exact ARN 축소
NACL 부재	SG 로만 통제	Data Subnet 중심 NACL 추가
SG egress 0.0.0.0/0 (443)	S3 Gateway EP 호환 임시	VPC Endpoint 전용으로 축소
단일 CMK	통합 키 관리	환자 식별정보 별도 CMK 분리
MFA 미강제	dev 편의	Phase 2 강제 활성화

참고 문서: AWS/AWS_Security_Design_v1.md, CloudFormation: security-stack.yaml

7.6 AWS 데이터베이스

담당: 홍경태

7.6.1 데이터 계층 설계 철학 — 단일 클러스터, 다중 책임 분리

본 시스템의 데이터 계층은 **Aurora Serverless v2** 단일 클러스터 + **2**개 논리 데이터베이스 (**central_db + hapi**) 의 통합 운영 방식으로 설계되었다. 모달 추론 결과소견서·감사 로그를 저장하는 운영 DB(central_db)와 FHIR R4 표준 자원을 저장하는 표준 DB(hapi)를 한 클러스터에서 운영함으로써, HA 비용을 단일화하면서도 스키마·권한·롤 레벨에서 책임을 명확히 분리한다.

계층	자원	용도	접근 주체
운영 DB	central_db (PostgreSQL 16)	모달 결과 · 소견서 · 감사 로그 · FCM 토큰	orchestrator · rag · ecg · cxr · lab
표준 DB	hapi (PostgreSQL 16, 동일 클러스터)	FHIR R4 자원 (Patient · Encounter · Observation 등)	HAPI FHIR EC2
원본 저장	S3 (say2-6team-bucket)	ECG WFDB · CXR PNG · ONNX 모델	6 모달 서비스 (Read)
RAG 인덱스	S3 (say2-6team-rag-db-...)	ChromaDB 인덱스 (372 MB)	rag-svc (Task 시작 시 다운로드)

7.6.2 Aurora Serverless v2 클러스터 — PostgreSQL 16 + ACU 0.5~4 Auto Scaling

`say2-6team-aurora-cluster` 는 PostgreSQL 16.4 호환 Aurora Serverless v2 클러스터로, EngineMode=provisioned + ServerlessV2ScalingConfiguration 조합으로 정의된다. ACU 단위로

vCPU-메모리-네트워크가 동시 스케일되며, 응급실 트래픽의 burst 패턴(야간 KTAS 12 환자 집중 후 idle)에 정합한다.

항목	설정값	선택 근거
Engine	aurora-postgresql 16.4	JSONB-GIN 인덱스-pgaudit 안정 지원, FHIR R4 호환
EngineMode	provisioned + Serverless v2	Aurora Serverless v2 전제 (v1 과 별도)
MinCapacity	0.5 ACU	idle 시 비용 floor (1 ACU $\approx$ 2 GB RAM + 0.25 vCPU 등가)
MaxCapacity	4.0 ACU	5 모달 동시 + RAG 병렬 쓰기 가능한 ceiling
Auto Scaling 트리거	CPU · Connections · 메모리 자동	별도 정책 불필요 (Aurora 내장)
Port	5432	PostgreSQL 표준
DeletionProtection	true	환자 데이터 실수 삭제 차단

ACU 0.5~4 비용 분석 (서울 리전)

시나리오	평균 ACU	시간당	월 환산	합의
Idle (새벽 4~6 시)	0.5	\$0.10	\$73	최소 floor
일반 운영 (낮 시간)	1.5	\$0.30	\$219	평균 사용
Burst (야간 응급 피크)	4.0	\$0.80	(피크 시간 한정)	ceiling
월 추정 평균	1.2 ACU 가중평균	—	약 \$175~210/월	일반 RDS 대비 약 40% 절감

전통적 RDS db.r6g.large 인스턴스(2 vCPU / 16 GB) 단일 운영 시 약 \$350/월인 반면, Aurora Serverless v2 는 idle 시간이 많은 응급실 패턴에서 약 40% 비용 절감이 가능하다.

7.6.3 1 클러스터 × 2 Database 통합 운영 근거

central_db(운영 데이터)와 hapi(FHIR 표준 데이터)를 동일 Aurora 클러스터의 별도 데이터베이스로 분리 운영하는 설계 결정에는 다음의 정량정성 근거가 있다.

선택 근거	단일 클러스터 + 2 DB 분리	2 클러스터 분리 운영 시
비용	ACU 공유 → 약 \$175~210/월	클러스터 2 개 × ACU floor →

선택 근거	단일 클러스터 + 2 DB 분리	2 클러스터 분리 운영 시
		약 \$350~400/월 (2 배)
HA 설정	1 회 (Writer + Reader)	2 회
KMS Key	1 개 통합 관리	2 개 분산 관리
백업 윈도우	1 회 (UTC 03:00-04:00)	2 회 충돌 가능
권한 분리	DB·롤·스키마 레벨로 충분 (PostgreSQL 표준)	클러스터 레벨 (과잉)
마이그레이션	Alembic 1 회 + HAPI JPA 1 회	동일
장애 영향 범위	클러스터 장애 시 양쪽 영향 (BCP/DR 로 대응)	양쪽 독립 (단, 비용 부담 큼)

권한 분리는 PostgreSQL 표준 메커니즘으로 충분히 강력하다. master 계정(dbadmin)이 DDL 을 담당하고, 애플리케이션은 hapi_user(hapi DB 전용)와 IAM Database Authentication 기반 ECS Task Role 로 접근하여 클러스터 분리 없이도 책임이 명확히 격리된다.

hapi DB 자동 프로비저닝 — Lambda Custom Resource

hapi DB 와 hapi_user 는 CloudFormation Custom Resource(Lambda + RDS Data API)로 자동 생성 된다. 운영자가 수동으로 SQL 을 실행하지 않고도 스택 배포 시점에 DB·롤·권한·OWNER 가 일 관되게 설정되어 재현 가능한 인프라가 보장된다.

단계	SQL	함의
1	CREATE ROLE hapi_user WITH LOGIN PASSWORD '<from Secrets Manager>';	자동 생성 비밀번호 32 자
2	GRANT hapi_user TO CURRENT_USER;	DB owner 권한 위임을 위한 사전 GRANT
3	CREATE DATABASE hapi OWNER hapi_user;	hapi DB 생성 + 소유권 hapi_user
4	GRANT ALL PRIVILEGES ON DATABASE hapi TO hapi_user;	DB-level 권한
5	GRANT ALL ON SCHEMA public + ALTER SCHEMA public OWNER TO hapi_user;	hapi DB 내 public 스키마 owner 이전

7.6.4 3-AZ × 6 복제 + Failover 30 초 자동

Aurora 의 분산 스토리지는 3 AZ × 2 copy = 총 6 복제본으로 자동 구성되며 (Aurora 아키텍처 표준), 본 시스템은 Writer + Reader 2-인스턴스 토폴로지로 단일 AZ 장애 시 자동 페일오버를 보장한다.

인스턴스	PromotionTier	DBInstanceClass	역할
say2-6team-aurora-writer	0 (Primary)	db.serverless	모든 쓰기 + 읽기
say2-6team-aurora-reader	1 (Failover 후보)	db.serverless	읽기 부하 분산 + Failover 대기
요구사항	메커니즘	목표	
스토리지 복제	6-way 자동 복제 (3 AZ × 2)	RPO ≈ 0 (동기 복제)	
Writer 장애 시 Failover	Reader → Writer 자동 승격	RTO 30 초 (Aurora SLA)	
백업	BackupRetentionPeriod 7 일 + UTC 03:00-04:00	RPO 5 분 (PITR 가능)	
Cross-AZ 가용성	DBSubnetGroup × 2 (Private Data A/C)	단일 AZ 장애 무영향	
Performance Insights	활성 + KMS 암호화 + 7 일 보존	쿼리 단위 진단	
DeletionPolicy	Snapshot	스택 삭제 시에도 데이터 보존	

백업 윈도우는 UTC 03:00-04:00 = KST 12:00-13:00(점심시간, 응급실 트래픽 저점)으로 설정되어 백업 IO 부하가 임상 응답성에 영향을 주지 않는다.

7.6.5 central_db 스키마 설계 — Operations Layer

central_db 는 ML/LLM 추론 결과의 운영 데이터 레이어로, FHIR 표준(hapi DB)과 분리하여 추론 결과·근거·감사 로그 등 자체 도메인 데이터를 저장한다.

테이블	PK	주요 컬럼	용도
ops_encounters	encounter_id (UUID)	patient_ref, arrival_time, ktas, chief_complaint, disposition, status	응급실 방문 1 건 = 1 row
ops_modal_results	result_id	encounter_id (FK), modal_type, result_json (JSONB), confidence, latency_ms, model_version	ECG/CXR/Lab 추론 결과
ops_reports	report_id	encounter_id (FK), section_1~9 (JSONB), bedrock_model_id, signed_by, signed_at,	9 섹션 한국어 소견서

테이블	PK	주요 컬럼	용도
		signature_hash	
audit_log	log_id (BIGSERIAL)	timestamp, actor, action, resource, ip, request_id, payload_hash	모든 판단근거 ·timestamp (법적방어 핵심)
device_tokens	token_id	user_id, fcm_token, device_type, last_active, valid_until	FCM Critical Push 라 우팅
fhir_sync_queue	sync_id	resource_type, payload (JSONB), retry_count, last_attempt, status	HAPI 동기화 실패 재 시도 큐

7.6.6 JSONB + GIN 인덱스 활용 — 모달 결과 저장

ECG/CXR/Lab 모달은 결과 구조가 모달별·버전별로 상이하므로 JSONB 컬럼 + GIN 인덱스 조합으로 스키마 유연성과 쿼리 성능을 동시에 확보한다.

ops_modal_results 스키마 예시

```
CREATE TABLE ops_modal_results (result_id BIGSERIAL PRIMARY KEY, encounter_id UUID NOT NULL REFERENCES ops_encounters(encounter_id), modal_type VARCHAR(16) NOT NULL, result_json JSONB NOT NULL, confidence FLOAT, latency_ms INT, model_version VARCHAR(32), created_at TIMESTAMPTZ NOT NULL DEFAULT NOW());
```

```
CREATE INDEX idx_modal_results_json ON ops_modal_results USING GIN (result_json jsonb_path_ops);
```

```
CREATE INDEX idx_modal_results_encounter_modal ON ops_modal_results (encounter_id, modal_type, created_at DESC);
```

JSONB 활용 사례

쿼리 유형	JSONB 표현	인덱스
ECG 에서 acute_mi > 0.5 인 케이스	result_json @> '{"diseases": {"acute_mi": {"probability":0.5}}}'	GIN
CXR 에서 Pneumothorax 검 출	result_json -> 'predictions' ->> 'pneumothorax_flag' = 'true'	GIN
Lab Critical Flag 발생 케이스	result_json -> 'critical_flags' ? 'K_HIGH'	GIN
특정 encounter 의 모달 시계 열	WHERE encounter_id = ? ORDER BY created_at DESC	B-tree

7.6.7 마이그레이션 전략 — Alembic + run-migrations.sh

스키마 변경은 Alembic(Python SQLAlchemy migration)으로 버전 관리되며, 배포 자동화는 `run-migrations.sh` 스크립트가 RDS Data API + Aurora Secrets Manager 통합으로 처리한다.

단계	명령어 / 동작	함의
1. 개발	alembic revision --autogenerate -m "<msg>"	SQLAlchemy 모델 diff 자동 생성
2. 리뷰	GitHub PR + DBA Approve	운영 DB 변경 검토 게이트
3. 배포	./run-migrations.sh --env=prod	ECS one-off Task 로 alembic upgrade head
4. 검증	alembic current + 스모크 테스트	헬스체크 통과 후 트래픽 전환
5. 롤백	alembic downgrade -1	직전 리비전 복귀

7.6.8 Backup 전략 — RPO 5 분 / RTO 30 초

백업 유형	빈도	보존	RPO	RTO
Automated Backup	매일 (UTC 03:00-04:00)	7 일	5 분 (PITR)	인스턴스 복구 30 분
Point-in-Time Recovery	연속 (transaction log)	7 일	5 분	—
Snapshot (Manual)	주요 마이그레이션 전	무기한	—	수동 트리거
Failover	자동	—	0 초 (Reader 즉시 승격)	30 초
DeletionProtection	활성	—	—	실수 삭제 차단
CopyTagsToSnapshot	활성	—	—	비용 추적 일관성

7.6.9 S3 라이프사이클 정책 — Tier 기반 비용 최적화

S3 는 원본 데이터·모델·RAG 인덱스의 영구 저장소로, 데이터 유형별 액세스 패턴에 따라 3-Tier 라이프사이클 정책을 적용한다.

버킷	용도	Standard	IA 전환	Glacier 전환	삭제
say2-6team-bucket (ECG WFDB)	환자 ECG 원본	30 일	30 일 → IA	1 년 → Glacier	7 년 (SaMD 추적성)
say2-6team-bucket (CXR PNG)	환자 CXR 원본	30 일	30 일 → IA	1 년 → Glacier	7 년
모델 ONNX	S6 Mamba · DenseNet · UNet	무기한	—	—	(버전 영구)
say2-6team-rag-db-666...	ChromaDB 인덱스	무기한	—	—	6 개월 주기 갱신
say2-6team-vpc-flow-logs	VPC Flow Logs	30 일	—	—	90 일 자동 삭제

비용 효과: 환자 원본 데이터는 30 일 이후 액세스 빈도가 급감하므로 IA 전환으로 약 45% 절감, 1년 이후 Glacier 전환으로 추가 75% 절감이 가능하다. 단, SaMD 추적성 요구로 **7 년** 보존 (의료법 §22 진료기록 보존 의무)은 유지한다.

7.6.10 HAPI FHIR PostgreSQL 백엔드 연동

HAPI FHIR EC2(t4g.medium 또는 t3.large 단일 인스턴스)는 동일 Aurora 클러스터의 hapi 데이터베이스를 백엔드로 사용한다.

연결 항목	값	합의
JDBC URL	jdbc:postgresql://<aurora-endpoint>:5432/hapi?sslmode=require	rds.force_ssl=1 - TLS 강제
자격증명	Secrets Manager say2-6team/hapi-credentials	EC2 UserData 에서 동적 조회
Hibernate Dialect	HapiFhirPostgresDialect	HAPI FHIR R4 호환
FHIR 버전	R4	식약처 권장
Connection Pool	JPA 기본 (HikariCP)	단일 EC2 워크로드 적정

orchestrator 는 `FHIR\_BASE\_URL=http://<hapi-ec2-private-ip>:8080/fhir` 환경변수로 HAPI 를 호출하며, 7.4.5 절에 명시한 대로 Phase 2 에서 Cloud Map / Route 53 사설 DNS 추상화 예정이다.

7.6.11 쿼리 성능 튜닝 사례

사례 1: 특정 환자의 최근 24 시간 모달 추론 결과 조회

Before (인덱스 없음, Seq Scan): `EXPLAIN ANALYZE SELECT * FROM ops_modal_results WHERE encounter_id = '<uuid>' AND created_at > NOW() - INTERVAL '24 hours' ORDER BY created_at DESC;` → Seq Scan, Execution Time: **845 ms**

After (B-tree 복합 인덱스 추가): `CREATE INDEX idx_modal_results_encounter_modal ON ops_modal_results (encounter_id, modal_type, created_at DESC);` → Index Scan, Execution Time: **4.2 ms** (200 배 개선)

사례 2: JSONB 키 검색 — Critical Flag 발생 케이스

Before (JSONB Full Scan): `SELECT encounter_id, result_json -> 'critical_flags' FROM ops_modal_results WHERE result_json @> '{"critical_flags": ["K_HIGH"]}';` → Execution Time: **1,240 ms** (50 만 row 기준)

After (GIN 인덱스 + jsonb_path_ops): `CREATE INDEX idx_modal_results_json ON ops_modal_results USING GIN (result_json jsonb_path_ops);` → Execution Time: **18 ms** (약 70 배 개선)

`jsonb_path_ops` 연산자 클래스는 일반 GIN 대비 인덱스 크기가 작고 `@>` 컨테이너 쿼리에 특화되어 있어, JSONB 결과 컬럼의 키 검색 패턴에 최적이다.

7.6.12 보안·감사 통합 (pgaudit + IAM Database Auth)

통제 항목	구현
At-Rest 암호화	StorageEncrypted: true + 전용 KMS Key (alias/say2-6team-aurora-kms)
Transit 암호화	rds.force_ssl=1 (DBClusterParameterGroup)
pgaudit	shared_preload_libraries: pgaudit + pgaudit.log: write,ddl
슬로우 쿼리 로깅	log_min_duration_statement: 1000 (1 초 이상)
IAM Database Auth	EnableIAMDatabaseAuthentication: true (ECS Task Role 기반)
Master Password	Secrets Manager 자동 생성 32 자 + Phase 2 자동 로테이션
Connection 격리	Security Group 9 종 매트릭스 (7.5.4 절)

참고 문서: AWS/AWS_DB_Design_v3.md, CloudFormation: aurora-stack.yaml, hapi-db-stack.yaml, data-rag-stack.yaml, hapi-fhir-ec2-stack.yaml

7.7 AWS 모니터링

담당: 홍경태

7.7.1 모니터링 설계 철학 — Infra · Modal · Clinical 3-Channel 분리

본 시스템의 모니터링은 인프라 알림 / 모달 추론 알림 / 임상 알림을 명확히 분리한다. 의료 시스템에서 알림은 단순 운영 메트릭이 아니라 환자 안전에 직결되는 신호이므로, 알림 경로의 우선순위·전달 채널·응답 SLA 가 다르게 설계되어야 한다.

채널	트리거	수신 대상	전달 방식	응답 SLA
Clinical Alert	KTAS 1 환자 · CXR Pneumothorax · Lab K>6.5 등	응급실 당직 의사	FCM Critical Push (모바일)	1 분 이내
Critical Infra	Aurora 메모리 부족 · ECS Task 0 개 · ALB 5xx · Modal 추론 실패	DevOps · 백엔드 리드	SNS Email + (확장: Slack)	5 분 이내
Warning Infra	CPU 80%+ · Connections 100+ · Latency 3s+	개발팀	SNS Email	1 시간 이내

본 7.7 절은 후자 두 인프라 채널을 담당한다. 임상 알림(FCM Critical Push)은 백엔드 dispatcher 가 처리하며 본 스택과 분리되어 운영된다.

7.7.2 CloudWatch Logs 구성 — 7 개 LogGroup × 차등 보존

LogGroup	소스	보존	합의
/drai/central-backend	orchestrator	90 일	환자 판단 흐름 추적 (법적방어)
/drai/modal/ecg	ecg-svc	30 일	ML 추론 디버깅
/drai/modal/cxr	cxr-svc	30 일	ML 추론 디버깅
/drai/modal/lab	lab-svc	30 일	Rule Engine 추적
/drai/router	router-svc	30 일	폴백 라우팅 추적
/ecs/say2-6team-rag	rag-svc	30 일	Bedrock 호출 + ChromaDB 검색 추적
/drai/hapi-fhir	HAPI FHIR EC2	30 일	FHIR R4 트랜잭션

CloudWatch Logs 자체는 VPC Endpoint(com.amazonaws.<region>.logs)를 통해 NAT 없이 전송되어 보안비용 양면에서 유리하다(7.3.5 절).

7.7.3 CloudWatch Alarms 구성 — 23 개 알람 5 도메인

본 시스템은 5 개 도메인 23 개 알람으로 인프라와 추론 품질을 동시에 감시한다.
CloudFormation 의 Phase 조건부 생성(EnableEcsAlarms, EnableAlbAlarms)으로 단계적 활성화가 가능하다.

도메인	알람 수	CloudWatch Namespace	Phase
Aurora	4	AWS/RDS	Phase 1 (즉시)
ECS	12 (orchestrator + ECG + CXR + LAB 각 3)	AWS/ECS + ECS/ContainerInsights	Phase 2
ALB	4	AWS/ApplicationELB	Phase 2
Modal Custom	2	DRAI/Modal (애플리케이션 publish)	Phase 1
FHIR Sync	1	DRAI/FhirSync	Phase 1
합계	23	—	—

4 개 Aurora 알람 (Phase 1)

알람	메트릭	임계값	EvalPeriod	토픽
aurora-cpu-high	CPUUtilization	> 80%	10 분 (2 × 5 분)	Warning
aurora-acu-max	ServerlessDatabaseCapacity	> 3.6 ACU (max 90%)	15 분	Critical
aurora-connections-high	DatabaseConnections	> 100	10 분	Warning
aurora-memory-low	FreeableMemory	< 256 MB	10 분	Critical

12 개 ECS 알람 (Phase 2)

orchestrator + ECG + CXR + LAB 각 서비스마다 CPU / Memory / TaskDown 3 종 알람 적용:

알람 패턴	메트릭	임계값	토픽
ecs-<svc>-cpu-high	CPUUtilization (AWS/ECS)	> 80%	Warning
ecs-<svc>-memory-high	MemoryUtilization (AWS/ECS)	> 85%	Warning
ecs-<svc>-tasks-zero	RunningTaskCount	< 1	Critical + breaching

알람 패턴	메트릭	임계값	토픽
	(ECS/ContainerInsights)		

특히 **TaskDown** 알람은 `TreatMissingData: breaching`으로 설정되어 메트릭 미수신 자체를 장애로 간주한다 — 응급실에서는 "데이터가 없다"는 것이 가장 위험한 시그널이다.

4 개 ALB 알람 (Phase 2)

알람	메트릭	임계값	함의
alb-elb-5xx-high	HTTPCode_ELB_5XX_Count	> 10/5 분	ALB 자체 장애 (인프라)
alb-target-5xx-high	HTTPCode_Target_5XX_Count	> 10/5 분	백엔드 컨테이너 장애 (앱)
alb-latency-high	TargetResponseTime	> 3 초 평균	응답성 저하
alb-unhealthy-hosts	UnHealthyHostCount	≥ 1	Target Group 헬스체크 실패

3 개 애플리케이션 커스텀 알람 (Phase 1)

알람	Namespace	메트릭	임계값	함의
modal-inference-error-spike	DRAI/Modal	InferenceErrorCount	≥ 3/5 분	모달 추론 실패 급증
modal-high-latency-spike	DRAI/Modal	HighLatencyCount (5 초 초과)	≥ 5/5 분	추론 지연
fhir-sync-queue-backlog	DRAI/FhirSync	QueueDepth	> 100 (10 분)	HAPI 동기화 실패 누적

모달 커스텀 메트릭은 `app/clients/modal\_http.py` 인터셉터가 `put\_metric\_data`로 publish 하고, FHIR 큐 깊이는 `app/agent/fhir\_retry\_worker.py`가 5 분 주기로 emit 한다.

7.7.4 SNS 토픽 분리 — Critical vs Warning

알람 라우팅을 위해 2 개 SNS Topic 을 분리한다. 단일 토픽 운영 시 알람 우선순위 구분이 불가능해 야간 false alarm 으로 정작 진짜 critical 을 놓칠 위험이 있다.

Topic	TopicName	트리거 알람
CriticalAlertsTopic	say2-6team-critical-alerts	aurora-acu-max, aurora-memory-low, ecs-*-tasks-zero, alb-5xx, alb-unhealthy, modal-error-spike, fhir-backlog (총 13 개)

Topic	TopicName	트리거 알람
WarningAlertsTopic	say2-6team-warning-alerts	aurora-cpu-high, aurora-connections-high, ecs-* -cpu/memory-high, alb-latency-high, modal-latency-spike (총 10 개)

분리 근거

#	근거	임상·운영 합의
1	알람 피로(alert fatigue) 방지	CPU 80% 같은 잦은 warning 이 critical 신호를 가리지 않도록
2	야간 호출 권한 분리	Critical 만 oncall 호출, Warning 은 익일 처리
3	대응 SLA 차등화	Critical 5 분 / Warning 1 시간
4	향후 채널 확장 용이	Critical→PagerDuty/SMS, Warning→Slack 분기

7.7.5 Lambda Fan-Out — FCM Push / Slack / Email / SMS 라우팅 (확장 계획)

현재 Phase 1 은 SNS Email 직접 구독으로 단순화되어 있으나, Phase 2 운영 진입 시 SNS → Lambda Fan-Out 패턴으로 확장 예정이다. CloudWatch Alarm → SNS Topic (Critical / Warning) → Lambda Dispatcher → FCM Push / Slack Webhook / Email / SMS 의 4 채널 분기 구조다.

채널	사용 시점	합의
FCM Push	Critical Infra (모달 추론 실패 등)	백엔드 리드 모바일 → 5 분 내 1차 대응
Slack	전 알람	팀 공유 + 이력 보존
Email	전 알람	비휴대 시 보조
SMS	Critical only	Slack/FCM 미확인 시 fallback

임상용 FCM Critical Push(KTAS 1 환자 발생 등)는 별도 백엔드 dispatcher 가 처리하므로 본 모니터링 스택과 채널이 분리되어 있다.

7.7.6 핵심 SLO/SLA 지표 모니터링

본 시스템은 9.5 절의 응답 시간 SLA 를 실시간 모니터링한다. 애플리케이션 레벨에서 put_metric_data 로 publish 하고, CloudWatch Alarm + Dashboard 로 추적한다.

SLO 지표	목표 (p95)	모니터링 방법	Alarm 임계
ECG 추론 응답	< 1 초	DRAI/Modal/Latency Custom Metric (ecg)	p95 > 1.5s 5 분
CXR 추론 응답	< 1.5 초	DRAI/Modal/Latency (cxr)	p95 > 2.0s 5 분

SLO 지표	목표 (p95)	모니터링 방법	Alarm 임계
Lab 추론 응답	< 50ms	DRAI/Modal/Latency (lab)	p95 > 100ms 5 분
RAG 소견서 생성	< 8 초	DRAI/Modal/Latency (rag)	p95 > 12s 5 분
ALB - orchestrator	< 500ms	AWS/ ApplicationELB/ TargetResponseTime	> 3 초 평균
Aurora 쿼리 응답	< 100ms	log_min_duration_state ment: 1000 slow log	슬로우 쿼리 발생 시
Modal 추론 성공률	> 99%	InferenceErrorCount Spike 알람	≥ 3/5 분
FHIR 동기화 큐 깊이	< 50	DRAI/FhirSync/ QueueDepth	> 100/10 분

7.7.7 Critical Alert 정의 + 의사 호출 우선순위

본 시스템은 2 종의 critical 신호를 명확히 구분한다.

유형	트리거	수신	전달	응답 SLA
Clinical Critical	① 모달 결과 risk=CRITICAL (Pneumothorax, K>6.5, STEMI 의심 등) ② 미검토 KTAS 15 분 ↑ ③ 미서명 소견서 30 분 ↑	응급실 당직 의사 (Mobile)	FCM Critical Push (iOS Critical Alert / Android High-Priority)	1 분 이내
Infra Critical	Aurora 메모리 부족 · ECS Task 0 개 · ALB 5xx 급증 · Modal 추론 실패 · FHIR 큐 backlog	DevOps · 백엔드 리드	SNS Email - (Phase 2) FCM/SMS	5 분 이내

Clinical Critical 은 응급실 의사의 잠금 화면을 깨우는 알림이므로(8.4 절 Mobile 흐름 참조), Infra Critical 과 채널·우선순위·잠금화면 동작이 완전히 분리되어야 한다. 이 분리가 무너지면 인프라 false alarm 으로 진짜 환자 alert 이 묻힐 위험이 있다.

7.7.8 Dashboard 구성 — 운영용 + 임상용 분리

Dashboard	위젯 구성	수신 대상
Ops Dashboard	Aurora ACU/CPU/Connections · ECS Task Count × 6 서비스 · ALB 5xx/Latency · Modal Latency p50/p95/p99 · FHIR Queue Depth · 비용 트렌드	DevOps · 백엔드 리더
Clinical Dashboard	24 시간 환자 흐름 (Triage→Decision→Sign) · KTAS 분포 · 미서명 소견서 수 · 모달 추론 성공률 · 평균 D2D	응급실 의사 · 간호사

Dashboard 스크린샷은 별도 부록 H에 첨부 예정이다.

7.7.9 X-Ray / OpenTelemetry 분산 트레이싱 (Phase 2 도입 계획)

현재 Phase 1은 CloudWatch Logs + Metrics 중심이나, Phase 2 운영 진입 시 AWS X-Ray + OpenTelemetry SDK를 도입하여 다음 시나리오의 분산 트레이싱을 구현 예정이다.

트레이스 시나리오	추적 경로	함의
환자 1건 요청 lifecycle	ALB → orchestrator → ecg-svc + cxr-svc + lab-svc (병렬) → rag-svc → Bedrock → Aurora	병목 식별
Bedrock 호출 분포	rag-svc → Bedrock Runtime → Claude Haiku/Sonnet	토큰 사용량 + 응답 시간 모달별 분포
FHIR 동기화 실패 추적	orchestrator → fhir_sync_queue → HAPI EC2 → hapi DB	retry 패턴 분석

ECS Task Role에 `xray:PutTraceSegments` + `xray:PutTelemetryRecords` 권한을 추가하고, 컨테이너에 X-Ray Daemon 사이드카를 배치하는 방식이 표준이다.

7.7.10 비용 모니터링 — Cost Explorer + AWS Budgets

자원	모니터링	임계	알림 채널
월 총 비용	AWS Budgets	\$1,000/월 80%/100%	SNS Warning Email
Bedrock 호출 비용	Cost Allocation Tag (Project=say2-6team) + Daily	\$200/월 초과	SNS Warning
Aurora ACU 비용	Performance Insights + Cost Explorer	평균 ACU > 2.5 (1주)	수동 검토
S3 Storage	Storage Lens	1 TB 초과	Warning
Fargate Compute	Cost Explorer + Tag	\$900/월 (Baseline 110%)	Warning

태그 기반 비용 추적을 위해 모든 CloudFormation 리소스에 Project·Environment·Owner 3-Tag를 의무화하여, 팀원별 / 컴포넌트별 비용 분해가 가능하다.

7.7.11 장애 대응 Runbook — 5 분 내 1 차 대응

CloudWatch Alarm 발생부터 1차 조치까지의 표준 절차를 정의한다. 모든 단계는 5 분 내 1차 대응 + 30 분 내 정상화를 목표로 한다.

단계	시간	트리거	자동/수동	조치
1. Detect	0~1 분	CloudWatch Alarm	자동	SNS – Email/Slack 발송
2. Triage	1~3 분	oncall 수신	수동	Dashboard 확인 + 영향 범위 판단
3. Mitigate	3~5 분	임시 조치 결정	자동 + 수동	ECS force-new-deployment / Aurora Failover / WAF Block / router-svc 우회
4. Diagnose	5~15 분	근본 원인 분석	수동	CloudWatch Logs Insights + X-Ray Trace + pgaudit 슬로우 로그
5. Resolve	15~30 분	정상화	수동	정상화 확인 + Alarm OK 상태 복귀
6. Post-Mortem	24h 내	사후 분석	수동	Notion 문서화 + 룰북 업데이트

알람별 Runbook 매핑 예시

Alarm	1 차 조치 (5 분 내)
aurora-memory-low	MaxCapacity 4 – 6 ACU 일시 상향 (Stack Update)
ecs-orchestrator-tasks-zero	ECS Service Force New Deployment + 트래픽 router-svc 로 우회
alb-target-5xx-high	직전 Task Definition revision 으로 롤백
modal-inference-error-spike	해당 모달 컨테이너 재시작 + Bedrock fallback 활성화
fhir-sync-queue-backlog	HAPI EC2 재시작 + retry worker 수동 트리거

7.7.12 모니터링 설계의 한계 인식

한계	현재 (Phase 1)	개선 계획 (Phase 2~3)
SNS Email 만 운영	단순 구독	Lambda Fan-Out → FCM/Slack/SMS
X-Ray 미적용	CloudWatch Logs 중심	OpenTelemetry SDK 도입
알람 임계값 정적	CPU 80%, 메모리 85% 고정	시간대별 동적 임계 (야간 burst 학습)
Phase 2 ALB/ECS 알람 미배포	12 + 4 알람 toggle off	운영 진입 시 활성화
Custom Metric 한정	InferenceError + Latency + QueueDepth 만	모델 confidence 분포, RAG retrieval 품질 추가
임상용 Dashboard 미완	Ops Dashboard 우선	임상용 Dashboard 별도 개발

참고 문서: AWS/AWS_Observability_Design_v1.md, CloudFormation: monitoring-stack.yaml

7.8 BCP / DR (Business Continuity & Disaster Recovery)

응급의료 시스템의 24/7 가용성 보장을 위한 다층 방어 전략

7.8.1 가용성 목표

지표	목표값	근거
RPO (Recovery Point Objective)	5 분	Aurora PITR 최소 단위
RTO (Recovery Time Objective)	30 초	Aurora Failover SLA
가용성 SLA	99.95%	월 22 분 미만 다운타임 허용
AZ 장애 거동	무중단 운영	Multi-AZ + Cross-AZ LB

7.8.2 다층 BCP/DR 메커니즘

계층	메커니즘	복구 시간	합의
L1 Compute	ECS Service AZ-a + AZ-c 분산 (각 Task 1개 이상)	30 초	한 AZ 장애 시 다른 AZ 가 100% 처리
L2 DB	Aurora Multi-AZ Failover (Writer→Reader)	30 초	Aurora SLA 보장

계층	메커니즘	복구 시간	합의
L3 Storage	Aurora 6-way 복제 + S3 11 9's	0 초 (동기)	데이터 손실 ≈ 0
L4 Application	router-svc 폴백 (Central 장애 시)	즉시	ALB 가 /route/* 트래픽 자동 우회
L5 LLM	Bedrock direct fallback (rag-svc 장애 시)	즉시	기본 프롬프트로 직접 호출
L6 Backup	Aurora 자동 백업 7 일 + Snapshot	30 분 (PITR)	실수 삭제·논리 손상 복구

7.8.3 시나리오별 복구 절차

장애 시나리오	감지 방법	자동 조치	수동 조치
AZ-a 전체 장애	ECS Task Health Check	AZ-c Task 로 100% 트래픽	AZ-a 복구 후 재분산 검증
Aurora Writer 장애	CloudWatch Alarm + Aurora 감지	Reader $\rightarrow$ Writer 자동 승격	신규 Reader 인스턴스 추가
Central 오케스트레이터 장애	ALB Health Check 5xx	/route/* $\rightarrow$ router-svc 우회	Central Task 재시작 + 로그 분석
RAG svc 장애	rag-svc Health 실패	Bedrock direct fallback 활성화	ChromaDB 인덱스 재배포
HAPI FHIR 장애	HAPI Health Check	fhir_sync_queue 큐잉	EC2 재시작 + retry worker
전체 리전 장애 (Phase 3)	Route 53 Health Check	(향후) ap-northeast-1 도쿄 리전 페일오버	리전 복구 후 데이터 동기화

7.8.4 정기 DR 훈련 계획

주기	훈련 시나리오	검증 항목
매월	Aurora Failover (수동 트리거)	RTO 30 초 달성 + 트랜잭션 무손실
분기	AZ 격리 시뮬레이션	Cross-AZ 트래픽 자동 분산
반기	Central 강제 다운 + router-svc 폴백	BCP/DR 전 계층 통합 검증
연간	전체 시스템 복구 훈련 + 사용자 시연	Post-Mortem 보고서 작성

8. 프론트엔드 · UX

8.1 디자인 시스템 — 의료 환경 최적화

응급실 24/7 환경, 노안청각 저하장시간 근무를 고려하여 의료 도메인 특화 디자인 시스템을 구축했다.

원칙	구현	근거
고대비 색상	WCAG AAA (7:1+ 명도비)	야간 응급실 조명 환경
대형 글자	본문 16px 기본, 알림 24px+	노안 의사 50대+ 대응
색맹 친화	Critical=빨강+아이콘+밑줄 (3중 중복 신호)	남성 의사 색맹 8% 통계
One-thumb 모바일	주요 동작 화면 하단 + 단일 터치	스크럽한 손, 장갑 착용 상황
최소 클릭	주요 동작 3-tap 이내	Cognitive load 최소화

8.2 Web Frontend — 의사 모니터링 스테이션

항목	기술 / 구현
프레임워크	React 18 + Vite + TypeScript
스타일링	Tailwind CSS + shadcn/ui 일부
상태 관리	Zustand + TanStack Query
실시간	WebSocket /ws/encounter/{id} (Critical Push)
주요 페이지	트리아지 입력, 환자 모니터링 보드, 모달 결과 상세, 9섹션 소견서 뷰어
배포	CloudFront + S3 정적 호스팅 (Vite build → S3 sync)

8.3 Mobile App — 의사용 임상 알림

항목	기술 / 구현
프레임워크	Flutter 3 + Riverpod
인증	Cognito + Face ID 생체 서명
알림	FCM Critical Push (잠금 화면 깨우기)

항목	기술 / 구현
주요 화면	Critical 알림 리스트, 환자 상세, 소견서 서명, 진료 이력

8.4 핵심 UX 플로우

#	단계	사용자	주요 화면 / 동작
①	트리아지 입력	간호사 (Web)	주호소·KTASV/S 입력 → 환자 큐 등록
②	AI 모달 실행	(자동, Central)	ECG/CXR/Lab 능동 호출 (Loading 표시)
③	결과 검토	의사 (Web)	모달별 카드 + 9 섹션 소견서 미리보기
④	Critical 알림	의사 (Mobile)	잠금 화면 push → 1-tap 환자 화면
⑤	Face ID 서명	의사 (Mobile)	생체 인증 → DocumentReference 서명
⑥	완료 / 전원	의사 + 간호사	전원 결정 → 동의서 → 종결

9. 성능 평가 및 검증

9.1 모델 성능 — 5 Case 골든셋 검증

Case	주호소	KT AS	예상 결과	실제 AI 판단	정확도
1	흉통 + 호흡곤란 + 양측 폐 수포음	2	STEMI 의심	ECG STEMI HIGH + CXR Edema + Trop ↑	✓
2	발열 + 의식저하 + 빈호흡	1	패혈증 의심	Lab Lactate>4 + CRP↑ + CXR Pneumonia	✓
3	호흡곤란 + 흉통 + 한쪽 폐음 감소	2	기흉 의심	CXR Pneumothorax CRITICAL + Trachea 편위	✓
4	두통 + 좌측 마비 + 의식저하	1	급성 뇌졸중	ECG AFib + Lab 정상 + RAG Note 유사 사례	✓
5	복통 + 흑변 + 빈맥	3	GI 출혈 + 빈혈	Lab Hb<8 + BUN/Cr ↑ + Cross match	✓

9.2 ECG S6 Mamba 최종 성능

지표	값	비교 기준
Macro AUROC	0.814	ECG-MIMIC 논문 0.78~0.81
Tier 1 (사망률 $\geq 10\%$) AUROC	0.809	—
Tier 2 (5~10%) AUROC	0.844	—
Macro F1 (threshold 0.30)	0.42	Multi-label 임계 우선 회수율
Inference Latency (ONNX, CPU)	150~280ms	AWS Fargate 1 vCPU

9.3 CXR 모달 성능

지표	값
6-disease Macro AUROC	0.86
Pneumothorax Recall (놓침 방지 우선)	0.92

지표	값
UNet IoU (Lung segmentation)	0.94
Inference Latency (ONNX, CPU)	150~300ms

9.4 Lab Rule Engine 성능

지표	값
11 Critical Flag Recall	100% (결정론적)
7 Profile 매칭 정확도	98.5%
Inference Latency	< 10ms
XGBoost 6h Prognosis AUROC	0.78~0.83 (라벨 별)

9.5 End-to-End 응답 시간 SLA

단계	p50	p95	p99	목표 (p95)
Triage 입력 → 환자 큐 등록	120ms	350ms	520ms	< 500ms
ECG 추론	180ms	420ms	680ms	< 1.0s
CXR 추론	220ms	850ms	1.3s	< 1.5s
Lab Stage A 평가	8ms	25ms	48ms	< 50ms
RAG 소견서 생성 (Haiku)	4.2s	6.8s	8.4s	< 8s
End-to-End (전체)	5.5s	9.2s	12.5s	< 15s

9.6 부하 테스트 결과

시나리오	동시 환자	결과
일반 운영 (낮 시간)	5 명/분	p95 5.2s, Error 0%
야간 burst	15 명/분	p95 8.4s, Error 0%, Auto Scaling 트리거

시나리오	동시 환자	결과
대형 사고 (Mass Casualty)	30 명/분	p95 12.8s, Error 1.2% (router-svc 풀백 활성화)

10. 사업적 의의 · 기술적 의의 · 확장성

10.1 시장 가치 정량화

2024 통계연보 기준 AI 개입 가능 전원 비중 54.4% × 연 13.3 만건 전원 = 연 약 **72,000 건**의 AI 개입 가능 케이스가 정량 시장이다.

지표	Phase 1 (1 년)	Phase 2 (3 년)	Phase 3 (5 년)
타깃 기관 수	지역응급의료센터 5~10 개	지역응급의료센터 50 개+	전국 528 개 50%+
SaaS 단가 (기관당)	월 500 만원	월 800 만원	월 1000 만원
ARR (예상)	약 5~10 억	약 45~60 억	약 200 억+

10.2 기술적 의의

차별점	내용
S6 Mamba ECG 4 가지 차별화	ED 첫 ECG + 24 라벨 임상 선정 + 인구통계 결합 + 30 일 사망률 가중 BCE
Active Cross-Modal Routing	Chief Complaint - 능동 모달 호출 (최대 3 loop)
Hybrid Decision Engine	Rule(결정론) + ML(확률) + LLM(추론) 3-tier 통합
Bedrock 동적 라우팅	Haiku/Sonnet 케이스별 자동 분기, 비용 80% 절감
한국 의료 특화	KTAS-NEDIS9 섹션 한국어 소견서·FHIR R4
SaMD 추적성 by-Design	audit_log + RAG 근거 인용 + DocumentReference 서명

10.2.1 GPU-Free Fargate 비용 효과

S6 Mamba(9M) + DenseNet(28MB) + UNet(84MB) 모두 CPU 추론 친화적으로 설계되어 GPU 인스턴스 대비 약 **70%** 비용 절감 + 운영 부담 최소화.

10.2.2 Bedrock Haiku/Sonnet 동적 라우팅

Sonnet 전용 운영 대비 약 **80%** 비용 절감 (Haiku 1 토큰당 단가가 Sonnet 의 1/12). 의료 자문급 추론이 필요한 케이스만 선별적 Sonnet 활용.

10.3 확장 로드맵

Phase	기간	확장 영역
Phase 1	2026~2027	지역응급의료센터 5~10 개 Silent - Shadow - Prospective

Phase	기간	확장 영역
Phase 2	2027~2029	지역응급의료센터 50+ + 모달 추가 (CT, US, EMR) + 도쿄 리전 페일오버
Phase 3	2029~2031	전국 528개 응급의료기관 50%+ + 동남아 시장 (싱가포르·태국)

11. 검증 로드맵 및 인허가

11.1 Silent → Shadow → Prospective 3 단계

단계	기간	방식	목표
Silent	3~6개월	백그라운드 추론, 의사에게 결과 미노출	안전성 검증 + 데이터 축적
Shadow	6~12개월	의사 판단 후 AI 결과 표시 → 비교	정확도 검증 + UX 피드백
Prospective	12개월~	의사 의사결정 보조 적극 활용	Outcome 개선 임상 시험

11.2 식약처 SaMD 인허가 트랙

등급	기준	본 시스템 해당	심사 기간
Class I	낮은 위험 (정보 제 공)	Lab Stage A Rule Engine	신고제
Class II	중간 위험 (의사결정 보조)	Hybrid Decision + 소견서	약 6~12개월
Class III	고위험 (자율 의사결정)	(해당 없음)	약 12~24개월

11.3 임상 IRB 및 데이터 거버넌스

- IRB 승인: 지역응급의료센터별 협력 병원 IRB
- 환자 데이터: 가명처리 + DocumentReference 서명 + 5년 보존
- 감사 추적: audit_log + CloudTrail 5년 보존
- 개인정보 영향평가(PIA): 사업 진입 전 의무

12. 결론

본 프로젝트(EMON Med®)는 2024 년 의료대란 이후 한국 응급의료 전달체계의 정량 위기 신호 — 응급실 이용 18.6% 급감, 전원 사유 26.6%의 「전문응급의료 요함」, 지역응급의료기관 응급의학 전문의 1.9 명/소 — 를 출발점으로 「응급실 야간 당직 의사결정 지원」을 단일 사용 시나리오로 정의하고, 이를 위한 멀티모달 능동형 AI 의사결정 지원 시스템을 6 주에 걸쳐 설계·구현·검증했다.

기술적 성과는 다음 다섯 가지로 요약된다. (1) **S6 Mamba ECG** 모델이 4 가지 차별화 (ED 첫 ECG·24 라벨 임상 선정·인구통계 결합·30 일 사망률 가중 BCE)로 Macro AUROC **0.814** 를 달성했다. (2) **UNet + DenseNet CXR** 모델이 6-disease 를 150~300ms 에 판독하며 Pneumothorax 등 긴장성 상태를 정량 측정값으로 감지한다. (3) **3-Stage Lab** 모델은 <10ms 결정론적 Rule + 7 CC Profile + XGBoost 6h 예후로 SaMD Class I 적합성과 놓침방지를 동시 확보했다. (4) **Bedrock Claude Haiku/Sonnet** 동적 라우팅으로 9 섹션 한국어 임상 소견서를 자동 생성하며 비용을 약 80% 절감했다. (5) **Active Cross-Modal Routing** 으로 Chief Complaint — 첫 모달 → 결과 → 다음 모달 결정을 최대 3 loop 으로 최적화했다.

AWS 인프라 측면에서는 ap-northeast-2(서울) 리전에 5 개 **CloudFormation** 스택(network·security·compute·aurora·monitoring)으로 ECS Fargate(GPU-free) + Aurora Serverless v2 + Bedrock + CloudFront(217 PoP) + Multi-AZ 구조를 배포하여 월 약 \$885 Baseline + 99.95% 가용성 SLA 를 달성했다.

Web 모니터링 스테이션(React 18) + Mobile 의사용 앱(Flutter + FCM Critical Push)을 통해 의사가 응급실 PC 를 떠나 있어도 골든타임을 확보할 수 있게 했으며, 5 Case 골든셋 검증(STEMI·패혈증·기흉·뇌졸중·GI 출혈) 모두를 통과했다.

정량적 시장 가치는 연 **7.2** 만건의 **AI** 개입 가능 전원(연 13.3 만건 × 54.4%)로 환산되며, Phase 1 Silent — Shadow — Prospective 3 단계 검증 로드맵과 식약처 SaMD Class II 인허가 트랙을 병행하여 5 년 내 전국 528 개 응급의료기관 50% 이상 도입을 목표한다.

13. 한계 및 향후 과제

13.1 데이터 한계 — MIMIC-IV vs NEDIS 도메인 격차

학습 데이터(MIMIC-IV BIDMC, 미국)와 적용 도메인(NEDIS, 한국)의 인구 구성·중증도 체계·EMR 표준언어가 상이하다. Phase 1 Silent 단계에서 한국 데이터 누적 후 fine-tuning 필요.

13.2 모델 한계

- ECG: Tier 3(낮은 사망률) 질환 AUROC 0.721 — 보강 필요
- CXR: 6-disease 외 질환(Atelectasis 미세 변화 등) Recall 한계
- Lab: XGBoost 6 시간 예측 학습 코호트(MIMIC ICU) 편향
- RAG: ChromaDB 372MB 정적 인덱스 — 6개월 주기 갱신

13.3 인프라 한계 (운영 진입 시 보강)

한계	개선 방향
WAF Count 모드	정상 트래픽 학습 후 Block 전환
IAM Wildcard prefix	exact ARN 으로 축소
NACL 부재	Data Subnet 중심 NACL hardening
Multi-Region 미구축	Phase 3 에서 도쿄 리전 페일오버
X-Ray 미적용	Phase 2 OpenTelemetry 도입
MFA 미강제	Phase 2 Cognito MFA 강제

13.4 임상 한계

- KTAS 12 중증 환자 중심 — KTAS 3 이하 데이터 보강 필요
- 소아산모·외상 등 특수 도메인 미커버
- Phase 1 검증 표본 5 Case — 골든셋 확장 필요

13.5 향후 과제 로드맵

기간	과제
~6 개월	Silent 단계 시작 (3 개 지역응급의료센터)
6~12 개월	한국 데이터 fine-tuning + Phase 2 알람 활성화
12~18 개월	SaMD Class II 인허가 제출 + Shadow 단계
18~24 개월	Prospective 임상 시험 + 모달 확장 (CT, US)

기간	과제
24~36개월	도쿄 리전 폐일오버 + 동남아 진출 검토

부록

부록 A. 코드 저장소 구조

- final/central : Central Orchestrator (FastAPI + Hybrid Decision Engine) - final/ecg-svc : S6 Mamba ECG ONNX 추론 - final/cxr-svc : UNet + DenseNet CXR - final/lab-svc : Rule Engine + XGBoost - final/rag-svc : Note RAG (Bedrock Claude + ChromaDB) - final/router-svc : Stateless Fallback - AWS/ : CloudFormation 5 개 스택 + Design Docs - frontend/ : React 18 + Vite Web - mobile/ : Flutter + Riverpod Mobile - design-system/ : 의료 도메인 디자인 토큰 - docs/ : 본 보고서 + 기술 문서

부록 B. API 명세 요약

각 마이크로서비스의 OpenAPI 3.0 Swagger 명세는 운영 환경에서 `/docs` 경로로 자동 게시된다. 핵심 엔드포인트는 7.2 절을 참조.

부록 C. DB 스키마 ERD

central_db (운영): ops_encounters · ops_modal_results · ops_reports · audit_log · device_tokens · fhir_sync_queue 6 개 테이블. hapi (FHIR): Patient · Encounter · Observation · DiagnosticReport · DocumentReference · ServiceRequest 등 FHIR R4 표준.

부록 D. 시연 영상

Case 1 (STEMI), Case 2 (패혈증), Case 3 (기흉), Case 4 (뇌졸중), Case 5 (GI 출혈) — 각 5~7 분 시연. [URL]에서 확인 가능.

부록 E. 참고문헌

- 중앙응급의료센터. (2025). 2024 응급의료 통계연보 (제 23 호).
- Gu, A., & Dao, T. (2023). Mamba: Linear-Time Sequence Modeling with Selective State Spaces.
- Johnson, A., et al. (2023). MIMIC-IV (version 2.2). PhysioNet.
- Wang, X., et al. (2017). ChestX-ray8: NIH Hospital-scale Chest X-ray Database. CVPR.
- 식품의약품안전처. (2022). 의료기기로서의 인공지능 소프트웨어 (SaMD) 가이드라인.
- Health Level Seven International. (2019). FHIR R4 Specification.
- AWS Documentation. (2026). Aurora Serverless v2 · ECS Fargate · Bedrock User Guide.

부록 F. 용어집

용어	정의
KTAS	Korean Triage and Acuity Scale, 한국 응급환자 분류도구 (Level 1~5)
NEDIS	National Emergency Department Information System, 국가응급진

용어	정의
	료정보망
SaMD	Software as a Medical Device, 의료기기로서의 소프트웨어
FHIR R4	Fast Healthcare Interoperability Resources Release 4, 의료 표준 데이터 모델
D2B	Door-to-Balloon time, 응급실 도착 → 관상동맥중재술 시간 (STEMI)
D2D	Door-to-Decision time, 응급실 도착 → 결정 시간
ICISS	International Classification of Diseases-Based Injury Severity Score, 중증외상 점수
KTAS 1~2	소생 / 긴급 — 본 시스템 우선 타깃
Critical Flag	Lab 결과 중 즉시 처치가 필요한 11개 항목 (K>6.5, Lactate>4 등)
Active Routing	능동형 모달 라우팅 — Chief Complaint 기반 첫 모달 선택 + 결과에 따른 다음 모달 결정
ACU	Aurora Capacity Unit, Aurora Serverless v2 용량 단위 (~ 2 GB RAM)
SLO/SLA	Service Level Objective / Agreement, 서비스 수준 목표 / 협약
BCP/DR	Business Continuity Plan / Disaster Recovery, 사업 연속성 / 재해 복구

— 본 보고서 끝 —